



Dimension Reduction

การลดมิติข้อมูลเป็นขั้นตอนสำคัญในการเรียนรู้ของเครื่อง ช่วยให้
อัลกอริทึมทำงานได้อย่างมีประสิทธิภาพมากขึ้นโดยการลดจำนวนแอตทริ
บิวต์ในชุดข้อมูล

Step of dimension reduction

ความรู้เฉพาะด้าน

การใช้ความเชี่ยวชาญในการลบ หรือรวมแอตทริบิวต์ที่ไม่จำเป็น

สรุปข้อมูล

ตรวจจับข้อมูลที่ซ้ำซ้อนระหว่างแอตทริบิวต์และลบออก

การแปลงข้อมูล

แปลงแอตทริบิวต์เชิงหมวดหมู่เป็นตัวเลข

PCA


สร้างแอตทริบิวต์ใหม่ที่เป็นค่าเฉลี่ยถ่วงน้ำหนักของแอตทริบิวต์เดิม

Introduction

ในการเรียนรู้ของเครื่อง มักพบสถานการณ์ที่มีแอตทริบิวต์จำนวนมากในฐานข้อมูล แม้ว่าจำนวนแอตทริบิวต์เริ่มต้นจะน้อย แต่จะมีการขยายตัวอย่างรวดเร็วในขั้นตอนการเตรียมข้อมูล

การรวมแอตทริบิวต์ที่มีความสัมพันธ์สูงหรือไม่เกี่ยวข้องกับแอตทริบิวต์เป้าหมายอาจนำไปสู่ overfitting และความแม่นยำในการทำนายอาจลดลง

ภัยเงียบ: เมื่อข้อมูลมี Attribute มากเกินไป



Cures of Dimensionality


มิติของโมเดลคือจำนวนตัวทำนายหรือแอตทริบิวต์อื่นพุตที่โมเดลใช้ โดย Cures of Dimensionality เกิดจากการเพิ่มแอตทริบิวต์เข้าไปในโมเดลข้อมูลหลายตัวแปร

เมื่อเพิ่มแอตทริบิวต์ พื้นที่ข้อมูลจะกระจายตัวมากขึ้น และโมเดลการจำแนกและการทำนายจะล้มเหลวเพราะข้อมูลที่มีไม่เพียงพอ ปัญหาที่เกิดจากการเพิ่มแอตทริบิวต์จะเพิ่มขึ้นแบบทวีคูณ

คำสาปแห่งมิติ (The Curse of Dimensionality)

เข้าใจว่าทำไมการเพิ่มคุณลักษณะ (มิติ) ให้กับโมเดลข้อมูลมากเกินไปจึงเป็นปัญหา

ยิ่งเพิ่มมิติ ข้อมูลยิ่งห่าง



เมื่อเพิ่มคุณลักษณะเข้าไปในโมเดล พื้นที่ข้อมูลจะกระจายตัวมากขึ้น ทำให้หารูปแบบที่สำคัญได้ยาก

ปัญหาโตแบบทวีคูณ



มิติ	ปริภูมิ
2 มิติ	ปริภูมิ 64
3 มิติ	ปริภูมิ 512

เพิ่ม 800%

การเพิ่มมิติเพียง 50% (จาก 2 เป็น 3) อาจทำให้ปริภูมิข้อมูลเพิ่มขึ้นถึง 800% (จาก 64 เป็น 512)



ทางออกคือ 'การลดมิติ'

ขั้นตอนสำคัญใน Machine Learning คือการคัดเลือกหรือลดจำนวนคุณลักษณะเพื่อเพิ่มความแม่นยำของโมเดล

© NotebookLM

Example 1: House Price in Boston

TABLE 4.1 **DESCRIPTION OF ATTRIBUTES IN THE BOSTON HOUSING DATASET**

CRIM	Crime rate
ZN	Percentage of residential land zoned for lots over 25,000 ft ²
INDUS	Percentage of land occupied by nonretail business
CHAS	Does tract bound Charles River? (= 1 if tract bounds river, = 0 otherwise)
NOX	Nitric oxide concentration (parts per 10 million)
RM	Average number of rooms per dwelling
AGE	Percentage of owner-occupied units built prior to 1940
DIS	Weighted distances to five Boston employment centers
RAD	Index of accessibility to radial highways
TAX	Full-value property tax rate per \$10,000
PTRATIO	Pupil-to-teacher ratio by town
LSTAT	Percentage of lower status of the population
MEDV	Median value of owner-occupied homes in \$1000s
CAT.MEDV	Is median value of owner-occupied homes in tract above \$30,000 (CAT.MEDV = 1) or not (CAT.MEDV = 0)?

Example 1: House Price in Boston








TABLE 4.2

FIRST NINE RECORDS IN THE BOSTON HOUSING DATA

CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	LSTAT	MEDV	CAT.MEDV
0.00632	18.0	2.31	0	0.538	6.575	65.2	4.09	1	296	15.3	4.98	24.0	0
0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242	17.8	9.14	21.6	0
0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242	17.8	4.03	34.7	1
0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222	18.7	2.94	33.4	1
0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222	18.7	5.33	36.2	1
0.02985	0.0	2.18	0	0.458	6.43	58.7	6.0622	3	222	18.7	5.21	28.7	0
0.08829	12.5	7.87	0	0.524	6.012	66.6	5.5605	5	311	15.2	12.43	22.9	0
0.14455	12.5	7.87	0	0.524	6.172	96.1	5.9505	5	311	15.2	19.15	27.1	0
0.21124	12.5	7.87	0	0.524	5.631	100.0	6.0821	5	311	15.2	29.93	16.5	0

Data Summaries

Summary Statistic

⬆ CRIM	Real	0		Min 0.006	Max 88.976	Average 3.614	Deviation 8.602
⬆ ZN	Real	0		Min 0	Max 100	Average 11.364	Deviation 23.322
⬆ INDUS	Real	0		Min 0.460	Max 27.740	Average 11.137	Deviation 6.860
⬆ CHAS	Integer	0		Min 0	Max 1	Average 0.069	Deviation 0.254
⬆ NOX	Real	0		Min 0.385	Max 0.871	Average 0.555	Deviation 0.116
⬆ RM	Real	0		Min 3.561	Max 8.780	Average 6.285	Deviation 0.703
⬆ ⚠ AGE	Real	0		Min 2.900	Max 100	Average 68.575	Deviation 28.149
⬆ DIS	Real	0		Min 1.130	Max 12.127	Average 3.795	Deviation 2.106
⬆ RAD	Integer	0		Min 1	Max 24	Average 9.549	Deviation 8.707
⬆ TAX	Integer	0		Min 187	Max 711	Average 408.237	Deviation 168.537

แสดงสถิติสรุปของชุดข้อมูล Boston Housing เราจะเห็นได้ทันทีว่าตัวแปรแต่ละตัวมีช่วงค่าที่แตกต่างกันมาก เราจะเห็นต่อไปว่าความแตกต่างของสเกลระหว่างตัวแปรสามารถทำให้ผลการวิเคราะห์คลาดเคลื่อนได้ หากไม่ได้รับการจัดการอย่างเหมาะสม ข้อสังเกตอีกประการหนึ่งจากการกระจายของข้อมูลคือ ค่าเฉลี่ยของตัวแปรตัวแรก CRIM (รวมถึงตัวแปรอื่น ๆ บางตัว) มีค่ามากกว่าค่ามัธยฐานอย่างชัดเจน ซึ่งบ่งชี้ว่าข้อมูลมีการเบ้ไปทางขวา ตัวแปรทั้งหมดไม่มีค่าสูญหาย นอกจากนี้ ยังไม่พบสัญญาณของค่าผิดปกติรุนแรงที่อาจเกิดจากการพิมพ์ข้อมูลผิด

Data Summaries

Summary Statistic

Attribut...	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	LSTAT	MEDV	CAT. ME...
CRIM	1	-0.200	0.407	-0.056	0.421	-0.219	0.353	-0.380	0.626	0.583	0.290	0.456	-0.388	-0.152
ZN	-0.200	1	-0.534	-0.043	-0.517	0.312	-0.570	0.664	-0.312	-0.315	-0.392	-0.413	0.360	0.365
INDUS	0.407	-0.534	1	0.063	0.764	-0.392	0.645	-0.708	0.595	0.721	0.383	0.604	-0.484	-0.366
CHAS	-0.056	-0.043	0.063	1	0.091	0.091	0.087	-0.099	-0.007	-0.036	-0.122	-0.054	0.175	0.109
NOX	0.421	-0.517	0.764	0.091	1	-0.302	0.731	-0.769	0.611	0.668	0.189	0.591	-0.427	-0.233
RM	-0.219	0.312	-0.392	0.091	-0.302	1	-0.240	0.205	-0.210	-0.292	-0.356	-0.614	0.695	0.641
AGE	0.353	-0.570	0.645	0.087	0.731	-0.240	1	-0.748	0.456	0.506	0.262	0.602	-0.377	-0.191
DIS	-0.380	0.664	-0.708	-0.099	-0.769	0.205	-0.748	1	-0.495	-0.534	-0.232	-0.497	0.250	0.119
RAD	0.626	-0.312	0.595	-0.007	0.611	-0.210	0.456	-0.495	1	0.910	0.465	0.489	-0.382	-0.198
TAX	0.583	-0.315	0.721	-0.036	0.668	-0.292	0.506	-0.534	0.910	1	0.461	0.544	-0.469	-0.274
PTRATIO	0.290	-0.392	0.383	-0.122	0.189	-0.356	0.262	-0.232	0.465	0.461	1	0.374	-0.508	-0.443
LSTAT	0.456	-0.413	0.604	-0.054	0.591	-0.614	0.602	-0.497	0.489	0.544	0.374	1	-0.738	-0.470
MEDV	-0.388	0.360	-0.484	0.175	-0.427	0.695	-0.377	0.250	-0.382	-0.469	-0.508	-0.738	1	0.790
CAT. ME...	-0.152	0.365	-0.366	0.109	-0.233	0.641	-0.191	0.119	-0.198	-0.274	-0.443	-0.470	0.790	1

ค่า correlation ระดับต่ำ และหลายคู่เป็นค่าลบ

Data Summaries

Aggregation and Pivot Tables

Pivot

Search text

CRIM
Number

ZN
Number

INDUS
Number

CHAS
Number

NOX
Number

RM
Number

AGE
Number

Retrive BostonHousing

Drag columns from the left to build a pivot table. ⓘ

Σ COMMIT PIVOT CLEAR TABLE CANCEL

Group-By

CHAS

+

Column Grouping

CHAS

MEDV
count

0 471

1 35

Aggregates

MEDV
count

+

2 rows - 2 columns (2 numerical)

ตารางสรุปแบบ pivot table แสดงจำนวนย่านที่อยู่อาศัยที่ติดกับแม่น้ำชาร์ลส์ เทียบกับย่านที่ไม่ติดแม่น้ำ (โดยเลือกตัวแปร CHAS เป็นตัวแปรสำหรับการจัดกลุ่ม) จากข้อมูลพบว่า ย่านที่อยู่อาศัยส่วนใหญ่ (471 จากทั้งหมด 506 ย่าน) ไม่ได้ติดกับแม่น้ำ

Data Summaries

Aggregation and Pivot Tables

Retrieve BostonHou...

Data Loading

Discretize by User Specification

Discretize RM

Edit Parameter List: classes

Edit Parameter List: classes

Defines the classes and the upper limits of each class.

class names	upper limit
3	4.0
4	5.0
5	6.0
6	7.0
7	8.0
8	9.0

Add Entry

Remove Entry

Apply

Cancel

Retrive BostonHousing (2)

Drag columns from the left to build a pivot table. ⓘ

Σ COMMIT PIVOT

CLEAR TABLE

CANCEL

Group-By

RM

Column Grouping

CHAS

RM	MEDV for 0.0 average	MEDV for 1.0 average
6	21.769	25.919
7	35.964	44.067
5	17.200	22.218
8	45.700	35.950
4	15.407	?
3	25.300	?

1 Group-by Column

1 Aggregate

Column Header: CHAS

6 rows - 3 columns (1 nominal, 2 numerical)

Aggregates


MEDV
average

Reducing the number of categories in Categorical Attributes

ปัญหา: หลาย Category ทำให้มีข้อมูลบวม




1 Feature
(m Groups)



m or m-1
Dummy Attributes


คุณลักษณะที่มี m กลุ่ม จะถูกแปลงเป็น Dummy Attributes
m หรือ m-1 ตัว ทำให้ชุดข้อมูลใหญ่ขึ้นมาก

ทางออก: รวมกลุ่ม Category ที่คล้ายกัน



ใช้ความเชี่ยวชาญและสามัญสำนึกในการรวมกลุ่มที่ใกล้เคียงกัน
หรือมีความสำคัญน้อย

เครื่องมือช่วย: ใช้ Pivot Table




เพื่อตรวจสอบขนาดของแต่ละกลุ่ม และดูผลกระทบต่อเป้าหมาย
(Target Attribute) เพื่อช่วยในการตัดสินใจ

เป้าหมายที่ควรถูกรวมเป็นหมวด




กลุ่มที่มีข้อมูลน้อยมาก




กลุ่มที่ไม่ช่วยแยกแยะประเภทของผลลัพธ์
(Class) ควรถูกรวมเป็นหมวด “อื่นๆ”

Reducing the number of categories in Categorical Attributes




กราฟนี้แสดงค่าเฉลี่ยของตัวแปรเป้าหมาย CAT.MEDV เมื่อจัดกลุ่มข้อมูลตามตัวแปร ZN พบว่าค่า ZN บางค่ามีพฤติกรรมของ CAT.MEDV เหมือนกันทั้งหมด จึงสามารถรวมค่า ZN ที่ให้ผลลัพธ์ใกล้เคียงกันเข้าด้วยกันเพื่อลดจำนวนหมวดหมู่และลดมิติของข้อมูลก่อนนำไปสร้างโมเดล

Reducing the number of categories in Categorical Attributes



กราฟรายได้รายไตรมาสของ Toys "R" Us ระหว่างปี 1992–1995 แสดงให้เห็นว่า ไตรมาสที่ 4 มีรูปแบบรายได้แตกต่างและสูงกว่าชัดเจน ในขณะที่ไตรมาสที่ 1–3 มีพฤติกรรมคล้ายกัน ดังนั้นจึงสามารถ รวมไตรมาสที่ 1–3 เป็นกลุ่มเดียว และแยกไตรมาสที่ 4 ออกต่างหาก เพื่อช่วยลดจำนวนหมวดหมู่และทำให้การวิเคราะห์ง่ายขึ้น

Principle Component Analysis



Example 2: Breakfast Cereals

TABLE 4.4 DESCRIPTION OF THE ATTRIBUTES IN THE BREAKFAST CEREAL DATASET	
Variable	Description
mfr	Manufacturer of cereal (American Home Food Products, General Mills, Kellogg, etc.)
type	Cold or hot
calories	Calories per serving
protein	Grams of protein
fat	Grams of fat
sodium	Milligrams of sodium
fiber	Grams of dietary fiber
carbo	Grams of complex carbohydrates
sugars	Grams of sugars
potass	Milligrams of potassium
vitamins	Vitamins and minerals: 0, 25, or 100, indicating the typical percentage of FDA recommended
shelf	Display shelf (1, 2, or 3, counting from the floor)
weight	Weight in ounces of one serving
cups	Number of cups in one serving
rating	Rating of the cereal calculated by consumer reports

Example 2: Breakfast Cereals

TABLE 4.3

SAMPLE FROM THE 77 BREAKFAST CEREALS DATASET

Cereal name	mfr	Type	Calories	Protein	Fat	Sodium	Fiber	Carbo	Sugars	Potass	Vitamins
100% Bran	N	C	70	4	1	130	10	5	6	280	25
100% Natural Bran	Q	C	120	3	5	15	2	8	8	135	0
All-Bran	K	C	70	4	1	260	9	7	5	320	25
All-Bran with Extra Fiber	K	C	50	4	0	140	14	8	0	330	25
Almond Delight	R	C	110	2	2	200	1	14	8		25
Apple Cinnamon Cheerios	G	C	110	2	2	180	1.5	10.5	10	70	25
Apple Jacks	K	C	110	2	0	125	1	11	14	30	25
Basic 4	G	C	130	3	2	210	2	18	8	100	25
Bran Chex	R	C	90	2	1	200	4	15	6	125	25
Bran Flakes	P	C	90	3	0	210	5	13	5	190	25
Cap'n'Crunch	Q	C	120	1	2	220	0	12	12	35	25
Cheerios	G	C	110	6	2	290	2	17	1	105	25
Cinnamon Toast Crunch	G	C	120	1	3	210	0	13	9	45	25
Clusters	G	C	110	3	2	140	2	13	7	105	25
Cocoa Puffs	G	C	110	1	1	180	0	12	13	55	25
Corn Chex	R	C	110	2	0	280	0	22	3	25	25
Corn Flakes	K	C	100	2	0	290	1	21	2	35	25
Corn Pops	K	C	110	1	0	90	1	13	12	20	25
Count Chocula	G	C	110	1	1	180	0	12	13	65	25
Cracklin' Oat Bran	K	C	110	3	3	140	4	10	7	160	25

Example 2: Breakfast Cereals

Row No.	calories	rating
1	70	68.403
2	120	33.984
3	70	59.426
4	50	93.705
5	110	34.385
6	110	29.510
7	110	33.174
8	130	37.039
9	90	49.120
10	90	53.314
11	120	18.043
12	110	50.765
13	120	19.824
14	110	40.400
15	110	22.736
16	110	41.445
17	100	45.863
18	110	35.783
19	110	22.397
20	110	40.449



Attribut...	calories	rating
calories	1	-0.689
rating	-0.689	1

AVG Calories: 106.883
SD Calories: 19.48
AVG Rating: 42.67
SD Rating: 14.05

Example 2: Breakfast Cereals

Attribut...	calories	rating
calories	1	-0.689
rating	-0.689	1

เป็นความสัมพันธ์เชิงลบ (Negative Relationship)

เครื่องหมาย ลบ (-) หมายความว่า

- ถ้า calories เพิ่ม → rating มีแนวโน้มลดลง

- ถ้า calories ลด → rating มีแนวโน้มเพิ่มขึ้น

ถ้าตัวแปรมีความสัมพันธ์สูง อาจเกิด Multicollinearity ซึ่งหมายถึงตัวแปรอิสระมีข้อมูลซ้ำซ้อนกัน ส่งผลให้ค่าสัมประสิทธิ์ของโมเดลไม่เสถียร การตีความผลทำได้ยาก และความแม่นยำในการพยากรณ์ลดลง

ถ้าลดมิติข้อมูล (dimension reduction) จะเสียข้อมูลไปมากหรือไม่

$$19.48^2 + 14.05^2 = 576.87$$

$$19.48^2 / 576.87 = 66\% \text{ ของ calories}$$

แสดงว่าเหลืออีก 34% เป็นของ rating

Example 2: Breakfast Cereals

Attribut...	calories	rating
calories	1	-0.689
rating	-0.689	1

เป็นความสัมพันธ์เชิงลบ (Negative Relationship)

เครื่องหมาย ลบ (-) หมายความว่า

- ถ้า calories เพิ่ม → rating มีแนวโน้มลดลง

- ถ้า calories ลด → rating มีแนวโน้มเพิ่มขึ้น

ถ้าตัวแปรมีความสัมพันธ์สูง อาจเกิด Multicollinearity ซึ่งหมายถึงตัวแปรอิสระมีข้อมูลซ้ำซ้อนกัน ส่งผลให้ค่าสัมประสิทธิ์ของโมเดลไม่เสถียร การตีความผลทำได้ยาก และความแม่นยำในการพยากรณ์ลดลง

ถ้าลดมิติข้อมูล (dimension reduction) จะเสียข้อมูลไปมากหรือไม่

$$19.48^2 + 14.05^2 = 576.87$$

$$19.48^2 / 576.87 = 66\% \text{ ของ calories}$$

แสดงว่าเหลืออีก 34% เป็นของ rating

Example 2: Breakfast Cereals

Attribut...	calories	rating
calories	1	-0.689
rating	-0.689	1

เป็นความสัมพันธ์เชิงลบ (Negative Relationship)

เครื่องหมาย ลบ (-) หมายความว่า

- ถ้า calories เพิ่ม → rating มีแนวโน้มลดลง

- ถ้า calories ลด → rating มีแนวโน้มเพิ่มขึ้น

ถ้าตัวแปรมีความสัมพันธ์สูง อาจเกิด Multicollinearity ซึ่งหมายถึงตัวแปรอิสระมีข้อมูลซ้ำซ้อนกัน ส่งผลให้ค่าสัมประสิทธิ์ของโมเดลไม่เสถียร การตีความผลทำได้ยาก และความแม่นยำในการพยากรณ์ลดลง


ถ้าลดมิติข้อมูล (dimension reduction) จะเสียข้อมูลไปมากหรือไม่

$$19.48^2 + 14.05^2 = 576.87$$

$$19.48^2 / 576.87 = 66\% \text{ ของ calories}$$

แสดงว่าเหลืออีก 34% เป็นของ rating

PCA (Principal Component Analysis)



Parameters

Principal Component Analysis


dimensionality reduction fixed number

number of components 2

Component	Standard Deviation	Proportion of Variance	Cumulative Variance
PC 1	22.316	0.863	0.863
PC 2	8.884	0.137	1.000

PCA (Principal Component Analysis) ExampleSet (Select Attributes) ExampleSet (Principal Component Analysis)			
Attribute	PC 1	PC 2	
calories	0.847	-0.532	
rating	-0.532	-0.847	

PCA



Component	Standard Deviation	Proportion of Variance	Cumulative Variance
PC 1	83.764	0.540	0.540
PC 2	70.914	0.387	0.926
PC 3	22.644	0.039	0.966
PC 4	19.181	0.028	0.994
PC 5	8.423	0.005	0.999
PC 6	2.092	0.000	1.000
PC 7	1.699	0.000	1.000
PC 8	0.780	0.000	1.000
PC 9	0.658	0.000	1.000
PC 10	0.370	0.000	1.000
PC 11	0.186	0.000	1.000
PC 12	0.063	0.000	1.000
PC 13	0.000	0.000	1.000

จากผลการวิเคราะห์ PCA พบว่าองค์ประกอบหลักเพียงไม่กี่ตัวสามารถอธิบายความแปรปรวนของข้อมูลได้ในสัดส่วนที่สูง โดย PC1 และ PC2 อธิบายความแปรปรวนสะสมได้มากกว่า 90 เปอร์เซ็นต์ และเมื่อใช้ประมาณ 4–5 Principal Components จะสามารถอธิบายข้อมูลได้มากกว่า 95 เปอร์เซ็นต์ แสดงว่าข้อมูลเดิมมีความซ้ำซ้อนกันสูง จึงสามารถลดมิติของข้อมูลได้อย่างมีประสิทธิภาพ ดังนั้น Principal Components ที่เลือกสามารถนำไปใช้ในการทำ regression หรือ classification ได้

PCA

Normalizing the Data

Attribute	PC 1	PC 2	PC 3	PC 4	PC 5	PC 6	PC 7	PC 8	PC 9	PC 10	PC 11	PC 12	PC 13
calories	-0.078	0.009	0.629	0.601	0.455	0.119	0.094	0.026	0.009	0.065	0.009	0.004	0.042
protein	0.001	-0.009	0.001	-0.003	0.056	0.113	0.258	-0.655	-0.202	-0.256	-0.045	-0.005	-0.616
fat	0.000	-0.003	0.016	0.025	-0.016	-0.132	0.373	0.118	0.124	-0.841	-0.062	-0.009	0.318
sodium	-0.980	-0.141	-0.136	0.001	0.014	0.023	0.005	-0.001	-0.004	-0.001	0.000	0.000	0.010
fiber	0.005	-0.031	-0.018	-0.020	0.014	0.263	0.043	0.659	0.227	-0.144	0.021	0.001	-0.648
carbo	-0.017	0.017	0.017	-0.026	0.349	-0.538	-0.672	-0.006	-0.025	-0.300	-0.042	0.014	-0.206
sugars	-0.003	0.000	0.098	0.115	-0.299	0.648	-0.567	-0.103	-0.117	-0.320	-0.028	0.019	0.136
potass	0.135	-0.987	0.037	0.042	-0.047	-0.050	-0.018	-0.015	0.001	0.006	0.000	0.001	0.006
vitamins	-0.094	-0.017	0.692	-0.714	-0.037	0.016	0.012	-0.004	0.012	0.001	-0.002	0.001	0.010
shelf	0.002	-0.004	0.012	-0.006	-0.008	-0.060	0.092	0.328	-0.935	-0.046	0.068	-0.010	0.000
weight	-0.001	-0.001	0.004	0.003	0.003	0.009	-0.024	0.003	0.002	0.006	-0.093	-0.995	0.000
cups	-0.001	0.002	0.001	-0.001	0.002	-0.010	-0.020	-0.062	0.054	-0.080	0.989	-0.092	-0.000
rating	0.075	-0.072	-0.308	-0.335	0.758	0.413	0.018	-0.012	-0.036	-0.023	0.003	0.003	0.188

ในตัวอย่างข้อมูลอาหารเข้าซีเรียล พบว่า principal component ตัวแรกถูกครอบงำด้วยปริมาณโซเดียม เนื่องจากโซเดียมมีค่าน้ำหนักสูงที่สุด แสดงว่า PC1 กำลังสะท้อนปริมาณโซเดียมเป็นหลัก ส่วน principal component ตัวที่สองสะท้อนปริมาณโพแทสเซียม สาเหตุสำคัญมาจากตัวแปรเหล่านี้วัดในหน่วยมิลลิกรัม ขณะที่สารอาหารอื่นวัดเป็นกรัม ทำให้ความแปรปรวนของโซเดียมและโพแทสเซียมสูงกว่าตัวแปรอื่น และส่งผลให้ PCA ให้ความสำคัญกับตัวแปรเหล่านี้มากเป็นพิเศษ

PCA

Normalizing the Data

Attribute	PC 1	PC 2	PC 3	PC 4	PC 5	PC 6	PC 7	PC 8	PC 9	PC 10	PC 11	PC 12	PC 13
calories	-0.300	0.393	0.115	0.204	-0.204	-0.256	0.026	-0.002	-0.030	0.500	-0.214	-0.492	0.234
protein	0.307	0.165	0.277	0.301	-0.320	0.121	-0.283	-0.427	-0.535	-0.022	0.032	0.100	-0.186
fat	-0.040	0.346	-0.205	0.187	-0.587	0.348	0.051	0.063	0.460	-0.145	-0.067	0.291	0.090
sodium	-0.183	0.137	0.389	0.120	0.338	0.664	0.284	0.177	-0.215	-0.001	-0.087	0.054	0.239
fiber	0.453	0.180	0.070	0.039	0.255	0.064	-0.112	0.216	0.244	0.295	-0.531	0.059	-0.442
carbo	-0.192	-0.149	0.562	0.088	-0.183	-0.326	0.260	0.167	0.117	0.241	0.179	0.476	-0.225
sugars	-0.228	0.351	-0.355	-0.023	0.315	-0.152	-0.228	-0.063	-0.225	0.252	-0.003	0.614	0.167
potass	0.402	0.301	0.068	0.091	0.148	0.025	-0.149	0.262	0.167	0.177	0.729	-0.121	0.128
vitamins	-0.116	0.173	0.388	-0.604	0.049	0.129	-0.294	-0.457	0.346	0.052	0.019	-0.000	0.060
shelf	0.171	0.265	-0.002	-0.639	-0.329	-0.052	0.175	0.414	-0.416	-0.046	-0.059	0.017	0.000
weight	-0.050	0.450	0.247	0.153	0.221	-0.399	-0.014	0.075	0.065	-0.692	-0.113	-0.031	0.000
cups	-0.295	-0.212	0.140	0.047	-0.121	0.099	-0.749	0.499	-0.050	-0.077	-0.055	-0.032	-0.000
rating	0.438	-0.252	0.182	0.038	-0.058	-0.186	-0.063	0.015	0.063	0.012	-0.276	0.189	0.743

PCA

Normalizing the Data

Component	Standard Deviation	Proportion of Variance	Cumulative Variance
PC 1	1.906	0.280	0.280
PC 2	1.774	0.242	0.522
PC 3	1.382	0.147	0.669
PC 4	1.010	0.078	0.747
PC 5	0.995	0.076	0.823
PC 6	0.850	0.056	0.879
PC 7	0.819	0.052	0.930
PC 8	0.645	0.032	0.962
PC 9	0.562	0.024	0.987
PC 10	0.303	0.007	0.994
PC 11	0.252	0.005	0.999
PC 12	0.139	0.001	1.000
PC 13	?	-0.000	1.000

Class work

4.1 Breakfast Cereals: ใช้ข้อมูลตัวอย่างซีเรียลอาหารเช้า Cereals.csv เพื่อสำรวจและสรุปข้อมูลตามหัวข้อต่อไปนี้

- a. ตัวแปรใดเป็นเชิงปริมาณ/เชิงตัวเลข (quantitative/numerical) ? ตัวแปรใดเป็นเชิงนามบัญญัติ (nominal) ?
- b. คำนวณค่า mean, median, min, max และ standard deviation สำหรับตัวแปรเชิงปริมาณแต่ละตัว ด้วย RapidMiner(หมายเหตุ: ค่าmedianของแต่ละตัวแปรสามารถคำนวณได้ด้วย Operation: Aggregate)
- c. แสดง histogram สำหรับตัวแปรเชิงปริมาณแต่ละตัว แล้วใช้อิสโตแกรมและสถิติสรุปเพื่อตอบคำถามต่อไปนี้
 - i. ตัวแปรใดมีความแปรปรวนสูงที่สุด ?
 - ii. ตัวแปรใดมีการกระจายแบบเบ้ (skewed) ?
 - iii. มีค่าข้อมูลใดที่ดูเหมือนจะเป็นค่าผิดปกติหรือสุดโต่ง (extreme) หรือไม่ ?
- d. แสดง boxplot เพื่อเปรียบเทียบปริมาณแคลอรีของซีเรียล ร้อน(H) กับ เย็น(C) กราฟนี้แสดงอะไรบ้าง ?
- e. แสดง boxplot ของ คะแนนความพึงพอใจผู้บริโภค (rating) โดยพิจารณาตาม ระดับความสูงของชั้นวาง (shelf) หากต้องการทำนายคะแนนความพึงพอใจจากระดับความสูงของชั้นวาง เราจำเป็นต้องเก็บทั้ง 3 ระดับ ของความสูงชั้นวางไว้หรือไม่? (Hint: แปลงตัวแปรความสูงชั้นวาง(shelf)ให้เป็นตัวแปรเชิงนามบัญญัติ โดยใช้ operation: Numerical to Polynomial เพื่อใช้จัดกลุ่มในการทำ boxplot)
- f. แสดงตารางสหสัมพันธ์ (correlation table) พร้อม ฮีตแมป (heatmap) สำหรับตัวแปรเชิงปริมาณ โดยใช้ Operation: Correlation Matrix
 - i. ตัวแปรคู่ใดมีความสัมพันธ์กันมากที่สุด ?
 - ii. เราจะลดจำนวนตัวแปรได้อย่างไรโดยอาศัยความสัมพันธ์เหล่านี้ ?
 - iii. ความสัมพันธ์จะเปลี่ยนไปอย่างไร หากทำการ ปรับมาตรฐาน/ทำ normalization ของข้อมูลก่อน ?
- g. นำข้อมูล Cereals.csv ทำการใช้ PCA (Principal Component Analysis) และ พิจารณาองค์ประกอบหลักตัวที่ 1 (Principal Component: PC1) จากการวิเคราะห์ตัวแปรเชิงตัวเลข 13 ตัว อธิบายโดยสังเขปว่า PC1 นี้แทนความหมายอะไร

Class work

4.2 Universities: ใช้ข้อมูลตัวอย่าง Universities.csv เพื่อตอบคำถามต่อไปนี้

- a. ลบตัวแปรเชิงจัดหมวดหมู่ทั้งหมดออก (Categorical attributes) (Hint: อย่าพิจารณาเฉพาะตัวแปรที่ระบบตีความเป็นชนิด Nominal เท่านั้น ต้องดูชนิดของข้อมูล) จากนั้นให้ลบแถวที่มีค่า missing values ออกจากชุดข้อมูลและแสดงผลลัพธ์ว่า เหลือ row กี่ row ในชุดข้อมูล
- b. นำชุดข้อมูลที่ได้ไปเข้า PCA (Principal Component Analysis) และตอบคำถามว่าควรจะใช้ PC กี่ตัวที่ควรจะไปใช้ในการวิเคราะห์ ML (Machine Learning) ที่สามารถอธิบายข้อมูลทั้งหมดได้ เกิน 90% และตัวไหนบ้าง