

Week 8: Regression wrap up and Random forest

กิตติรักษ์ ม่วงมิ่งสุข (กิ)

Last Modify: Jan 15, 2026

RMSE

- Linear regression on Boston Housing
- RMSE 4.786 +/- 0.000
- MEDV = ราคาบ้าน (1000\$)
- RMSE = 4.786 $\approx$ ผิดพลาดเฉลี่ย ~4,800 ดอลลาร์
- ค่า MEDV โดยประมาณ:
 - Min $\approx$ 5
 - Mean $\approx$ 22
 - Max $\approx$ 50
 - S.D. $\approx$ 9.2

RMSE เทียบกับ SD	คุณภาพโมเดล
$> SD$	แย่มาก
$\sim SD$	พอใช้
$< 0.6 * SD$	ดี
$< 0.4 * SD$	ดีมาก

RMSE $\approx$ 4.8 $\approx$ 52% ของ SD


± 0.000 แปลว่า ไม่มีความผันผวนระหว่าง fold (ควรใช้ k-fold cross-validation)

เทคนิคการเลือกตัวแปรเพิ่มเติม

- ใช้ operator “Weight by Correlation” เพื่อดูความสัมพันธ์ของตัวแปรต้น (x) แต่ละตัวกับ (y)
 - ค่าเข้าใกล้ 1: ตัวแปรนั้นมีความสัมพันธ์กับราคาบ้านสูงมาก (ไม่ว่าจะเป็นบวกหรือลบ)
 - ค่าเข้าใกล้ 0: ตัวแปรนั้นแทบไม่มีความสัมพันธ์กับราคาบ้านเลย
- แต่ Correlation วัดแค่ x_1 กับ y สัมพันธ์กันไหม โดยไม่สนใจตัวแปรอื่น แต่บางตัวแปรอาจจะ "เก่งเมื่ออยู่คู่กับตัวแปรอื่น"


attribute	weight
CHAS	0.175
DIS	0.250
ZN	0.360
AGE	0.377
RAD	0.382
CRIM	0.388
NOX	0.427
TAX	0.469
INDUS	0.484
PTRATIO	0.508
RM	0.695
LSTAT	0.738

Lab8-1 Weight by Correlation



พิจารณาตัวแปร ให้เหลือ 4 ตัว
โดยมีโมเดลมีประสิทธิภาพดีที่สุด
1. เหลือตัวแปรอะไรบ้าง
2. RMSE เท่าไหร่
3. Squared correlation เท่าไหร่

Random Forest



Random Forest Classifier using Scikit-learn




Image from: <https://www.geeksforgeeks.org/dsa/random-forest-classifier-using-scikit-learn/>

Benefits of Random Forest Classification:

- Random Forest can handle large datasets and high-dimensional data.
- By combining predictions from many decision trees, it reduces the risk of overfitting compared to a single decision tree.
- It is robust to noisy data and works well with categorical data.

Lab8-2 Random Forest



สรุป

- ถ้าอยากได้โมเดลแม่น ก็ random forest
- ถ้าอยากได้ตัวแปรน้อย ๆ อธิบายได้ ก็ linear regression ตัดตัวแปร



Q & A