

Week 9: Clustering

กิตติรักษ์ ม่วงมิ่งสุข (ก๊)

Last Modify: Jan 28, 2026

Clustering

- คือการนำข้อมูลที่ "ไม่มีฉลาก" (No Label) มาให้คอมพิวเตอร์หาความเหมือนและความต่างเอง
- Unsupervised Learning
- K-Means clustering
 - K คือจำนวนกลุ่มที่อยากให้แบ่ง (เราเป็นคนกำหนด)
 - การทำงาน:
 - 1. สุ่มจุดศูนย์กลาง (Centroid) ขึ้นมา k จุด
 - 2. “วัดระยะห่าง” ข้อมูลจุดไหนอยู่ใกล้ Centroid ไหนที่สุด ให้ไปเข้ากลุ่มนั้น
 - 3. คำนวณหาค่าเฉลี่ยของกลุ่มเพื่อขยับ Centroid ไปที่ตำแหน่งใหม่
 - 4. ทำซ้ำจนกว่าจุด Centroid จะนิ่ง หรือ ครบจำนวนรอบที่กำหนด

K-Means on iris data



Iris setosa



Iris versicolor



Iris virginica

Ref: https://en.wikipedia.org/wiki/Iris_flower_data_set


Sepal length ↕	Sepal width ↕	Petal length ↕	Petal width ↕	Species ↕
5.1	3.5	1.4	0.2	<i>I. setosa</i>
4.9	3.0	1.4	0.2	<i>I. setosa</i>

Iris data: <https://archive.ics.uci.edu/ml/machine-learning-databases/iris/iris.data>

SparkML kmean app:

<https://github.com/apache/spark/tree/branch-1.5/examples/src/main/python/mllib>

Ex. Iris K-means



Source: <http://stackoverflow.com/questions/6645895/calculating-the-percentage-of-variance-measure-for-k-means>

ระยะห่างแบบเส้นตรง

Euclidean distance

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

$$d(x, y) = \sqrt{(5.1 - 4.9)^2 + (3.5 - 3.0)^2 + (1.4 - 1.4)^2 + (0.2 - 0.2)^2}$$

$$d(x, y) = 0.538$$

Unknow Class = [5.1 3.5 1.4 0.2]

Iris-setosa = [4.9 3.0 1.4 0.2]



$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

$$d(x, y) = \sqrt{(5.1 - 6.4)^2 + (3.5 - 3.2)^2 + (1.4 - 4.5)^2 + (0.2 - 1.5)^2}$$

$$d(x, y) = 3.6166$$

Iris-versicolor = [6.4 3.2 4.5 1.5]

พีทาโกรัส และ ยุคลิด



รูปแรกมาจาก: <https://www.webythebrain.com/article/pythagoras-theorum-summary>

รูปที่สองมาจาก <https://byjus.com/maths/euclidean-distance/>

Lab9-1 K-Mean with Iris data

- ใช้ข้อมูลตัวอย่าง Iris ทำ K-Means Clustering

The screenshot displays a data science workflow interface with the following components:

- Repository:** A list of datasets including Deals, Deals-Testset, Golf, Golf-Testset, Iris (selected), Labor-Negotiations, Market-Data, Polynomial, and Products.
- Process:** A workflow diagram showing the sequence of operations:
 - Retrieve Iris:** The first step, which outputs data to the next step.
 - Select Attributes:** A step that filters the data based on selected attributes.
 - Clustering:** The K-Means Clustering step, which outputs cluster labels.
 - Performance:** A step that evaluates the clustering performance using a distance metric.
- Parameters:** A panel on the right showing the configuration for the Clustering (k-Means) step:
 - add cluster attribute:** Checked.
 - add as label:** Unchecked.
 - remove unlabeled:** Unchecked.
 - k:** Set to 3.
 - max runs:** Set to 10.
 - determine good start values:** Checked.
 - measure types:** Set to Numerical Measures.
 - numerical measure:** Set to Euclidean Distance.

ที่ Performance เลือก (Cluster Distance)

การวัดผล

- Davies-Bouldin Index: เป็นค่าที่บอกว่า กลุ่มแต่ละกลุ่มอยู่ห่างกันแค่ไหน และภายในกลุ่มเกาะกันแน่นไหม
 - ยิ่งค่าน้อย ยิ่งดี: หมายความว่าในกลุ่มเกาะกันแน่น และแต่ละกลุ่มแยกจากกันชัดเจน
- Elbow Method: การรับค่า k หลายๆ ค่า (เช่น 1-10) เพื่อหาจำนวนกลุ่มที่เหมาะสมที่สุด



การนำไปใช้ในธุรกิจ (Business Use Case)

- **Customer Segmentation:** แบ่งกลุ่มลูกค้าตามพฤติกรรม การซื้อ (เช่น กลุ่มประหยัด, กลุ่มเปย์หนัก, กลุ่มขาประจำ)
- **Anomaly Detection:** ข้อมูลไหนที่ไม่เข้าพวกกับกลุ่มใดเลย อาจจะเป็น "การทุจริต" (Fraud)
- **Inventory Management:** จัดกลุ่มสินค้าที่มักจะถูกซื้อพร้อมกันหรือมีรอบการหมุนเวียนคล้ายกัน

เพิ่มเติม



- ก่อนทำ Clustering ต้องทำ Normalize ข้อมูลเสมอ เพื่อให้ทุกตัวแปร (เช่น รายได้หลักแสน กับ อายุหลักสิบ) มีน้ำหนักเท่ากัน ไม่ให้ตัวแปรที่มีเลขเยอะๆ ข่มตัวแปรอื่น

Lab9-2: Optimize Parameters



Optimize Parameters

Edit Parameter Settings




Cluster Distance Performance

- Avg. Distance (Elbow Method) (Elbow แปลว่า ข้อศอก ~ หักศอก) Elbow Method: การรับค่า k หลายๆ ค่า (เช่น 1-10) แล้วดูจุดที่กราฟความผิดพลาดเริ่มนิ่งเหมือน "ข้อศอก" เพื่อหาจำนวนกลุ่มที่เหมาะสมที่สุด
- Davies-Bouldin Index (DBI) เป็นค่าที่บอกว่า กลุ่มแต่ละกลุ่มอยู่ห่างกันแค่ไหน และภายในกลุ่มเกาะกันแน่นไหม

Avg. Distance (Elbow Method)

(Elbow แปลว่า ข้อศอก ~ หักศอก)



Davies-Bouldin Index (DBI)

Optimize Parameters (Grid) (9 rows, 3 columns)

iteration	Clustering.k	Davies Bouldin
1	2	-0.265
2	3	-0.486
3	4	-0.561
4	5	-0.626
5	6	-0.689
6	7	-0.648
7	8	-0.628
8	9	-0.637
9	10	-0.741

ดูค่าบวกที่น้อยที่สุด
สำหรับ Rapidminer ดูค่าที่ใกล้ 0



Q & A