

Week 9: Clustering

กิตติรักษ์ ม่วงมิ่งสุข (กั)

Last Modify: Jan 28, 2026

Clustering

- คือการนำข้อมูลที่ "ไม่มีฉลาก" (No Label) มาให้คอมพิวเตอร์หาความเหมือนและความต่างเอง
- Unsupervised Learning
- K-Means clustering
 - K คือจำนวนกลุ่มที่อยากให้แบ่ง (เราเป็นคนกำหนด)
 - การทำงาน:
 - 1. สุ่มจุดศูนย์กลาง (Centroid) ขึ้นมา k จุด
 - 2. “วัดระยะห่าง” ข้อมูลจุดไหนอยู่ใกล้ Centroid ไหนที่สุด ให้ไปเข้ากลุ่มนั้น
 - 3. คำนวณหาค่าเฉลี่ยของกลุ่มเพื่อขยับ Centroid ไปที่ตำแหน่งใหม่
 - 4. ทำซ้ำจนกว่าจุด Centroid จะนิ่ง หรือ ครบจำนวนรอบที่กำหนด

K-Means on iris data



Iris setosa



Iris versicolor



Iris virginica

Ref: https://en.wikipedia.org/wiki/Iris_flower_data_set


Sepal length ⬆	Sepal width ⬆	Petal length ⬆	Petal width ⬆	Species ⬆
5.1	3.5	1.4	0.2	<i>I. setosa</i>
4.9	3.0	1.4	0.2	<i>I. setosa</i>

Iris data: <https://archive.ics.uci.edu/ml/machine-learning-databases/iris/iris.data>

SparkML kmean app:

<https://github.com/apache/spark/tree/branch-1.5/examples/src/main/python/mllib>

Ex. Iris K-means



Source: <http://stackoverflow.com/questions/6645895/calculating-the-percentage-of-variance-measure-for-k-means>

ระยะห่างแบบเส้นตรง

Euclidean distance

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

$$d(x, y) = \sqrt{(5.1 - 4.9)^2 + (3.5 - 3.0)^2 + (1.4 - 1.4)^2 + (0.2 - 0.2)^2}$$

$$d(x, y) = 0.538$$

Unknow Class = [5.1 3.5 1.4 0.2]

Iris-setosa = [4.9 3.0 1.4 0.2]



$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

$$d(x, y) = \sqrt{(5.1 - 6.4)^2 + (3.5 - 3.2)^2 + (1.4 - 4.5)^2 + (0.2 - 1.5)^2}$$

$$d(x, y) = 3.6166$$

Iris-versicolor = [6.4 3.2 4.5 1.5]

พีทาโกรัส และ ยุคลิด



รูปแรกมาจาก: <https://www.webythebrain.com/article/pythagoras-theorum-summary>

รูปที่สองมาจาก <https://byjus.com/maths/euclidean-distance/>

Lab9-1 K-Mean with Iris data

- ใช้ข้อมูลตัวอย่าง Iris ทำ K-Means Clustering

The screenshot displays a data science software interface with three main panels: Repository, Process, and Parameters.

- Repository:** A list of datasets is shown, with 'Iris' selected.
- Process:** A workflow diagram is visible, consisting of four steps: 'Retrieve Iris', 'Select Attributes', 'Clustering', and 'Performance'. The 'Clustering' step is highlighted in orange. The 'Performance' step is highlighted in yellow and includes a percentage icon, indicating that cluster distance is being measured.
- Parameters:** The 'Clustering (k-Means)' parameters are shown on the right. The 'k' value is set to 3, and 'max runs' is set to 10. The 'measure types' are set to 'Numerical Measures', and the 'numerical measure' is set to 'Euclidean Distance'.

ที่ Performance เลือก (Cluster Distance)

การวัดผล

- Davies-Bouldin Index: เป็นค่าที่บอกว่า กลุ่มแต่ละกลุ่มอยู่ห่างกันแค่ไหน และภายในกลุ่มเกาะกันแน่นไหม
 - ยิ่งค่าน้อย ยิ่งดี: หมายความว่าในกลุ่มเกาะกันแน่น และแต่ละกลุ่มแยกจากกันชัดเจน
- Elbow Method: การรับค่า k หลายๆ ค่า (เช่น 1-10) เพื่อหาจำนวนกลุ่มที่เหมาะสมที่สุด



การนำไปใช้ในธุรกิจ (Business Use Case)

- **Customer Segmentation:** แบ่งกลุ่มลูกค้าตามพฤติกรรม การซื้อ (เช่น กลุ่มประหยัด, กลุ่มเปย์หนัก, กลุ่มขาประจำ)
- **Anomaly Detection:** ข้อมูลไหนที่ไม่เข้าพวกกับกลุ่มใดเลย อาจจะเป็น "การทุจริต" (Fraud)
- **Inventory Management:** จัดกลุ่มสินค้าที่มักจะถูกรื้อพร้อมกันหรือมีรอบการหมุนเวียนคล้ายกัน

เพิ่มเติม

- ก่อนทำ Clustering ต้องทำ Normalize ข้อมูลเสมอ เพื่อให้ทุกตัวแปร (เช่น รายได้หลักแสน กับ อายุหลักสิบ) มีน้ำหนักเท่ากัน ไม่ให้ตัวแปรที่มีเลขเยอะๆ ข่มตัวแปรอื่น

Lab9-2: Optimize Parameters



Avg. Distance & Davies-Bouldin

Optimize Parameters (Grid) ×

Optimize Parameters (Grid) (9 rows, 3 columns)

iteration	Cluster...	Avg. within centroid distance
1	2	-0.576
2	3	-0.210
3	4	-0.130
4	5	-0.093
5	6	-0.074
6	7	-0.066
7	8	-0.053
8	9	-0.043
9	10	-0.038

ดูจุดอื่นตัว

k=3 ไป k=4: เริ่มลด
ลงน้อยลง (0.210
-> 0.130) = เริ่มอ้อม
ตัว

Optimize Parameters (Grid) (9 rows, 3 columns)

iteration	Clustering.k	Davies Bouldin
1	2	-0.265
2	3	-0.486
3	4	-0.561
4	5	-0.626
5	6	-0.689
6	7	-0.648
7	8	-0.628
8	9	-0.637
9	10	-0.741

ดูค่าบวกที่
น้อยที่สุด



Q & A