

Lab 3-1: การสำรวจและเตรียมข้อมูลด้วย RapidMiner

หัวข้อ: Data Visualization และ Dimension Reduction ชุดข้อมูล: BostonHousing.csv

วัตถุประสงค์:

1. ฝึกการนำเข้าข้อมูลและการตรวจสอบประเภทข้อมูล (Data Types)
2. ใช้เครื่องมือ Visualization เพื่อหาความสัมพันธ์ของราคาบ้านกับปัจจัยต่างๆ

TABLE 4.1 DESCRIPTION OF ATTRIBUTES IN THE BOSTON HOUSING DATASET

CRIM	Crime rate
ZN	Percentage of residential land zoned for lots over 25,000 ft ²
INDUS	Percentage of land occupied by nonretail business
CHAS	Does tract bound Charles River? (= 1 if tract bounds river, = 0 otherwise)
NOX	Nitric oxide concentration (parts per 10 million)
RM	Average number of rooms per dwelling
AGE	Percentage of owner-occupied units built prior to 1940
DIS	Weighted distances to five Boston employment centers
RAD	Index of accessibility to radial highways
TAX	Full-value property tax rate per \$10,000
PTRATIO	Pupil-to-teacher ratio by town
LSTAT	Percentage of lower status of the population
MEDV	Median value of owner-occupied homes in \$1000s
CAT.MEDV	Is median value of owner-occupied homes in tract above \$30,000 (CAT.MEDV = 1) or not (CAT.MEDV = 0)?

ชื่อตัวแปร	ความหมาย (แปลไทย)	คำอธิบายเชิงธุรกิจ
CRIM	อัตราอาชญากรรมต่อหัว	พื้นที่ที่มีอาชญากรรมสูง มักส่งผลลบต่อราคาบ้าน
ZN	สัดส่วนพื้นที่ดินจัดสรรขนาดใหญ่	บอกถึงความเป็นย่านที่พักอาศัยระดับหรู
INDUS	สัดส่วนพื้นที่อุตสาหกรรม	ย่านโรงงานเยอะ อาจมีมลภาวะหรือเสียงดัง
CHAS	ติดแม่น้ำ Charles หรือไม่?	ตัวแปรหุ่น (Dummy): 1 = ติดแม่น้ำ (วิวดี), 0 = ไม่ติด
NOX	ความเข้มข้นของก๊าซไนโตรเจนออกไซด์	ดัชนีวัดมลพิษทางอากาศในพื้นที่นั้น
RM	จำนวนห้องเฉลี่ยต่อหลัง	สำคัญมาก: บ้านห้องเยอะ ราคา มักจะสูงตาม
AGE	สัดส่วนบ้านเก่า (สร้างก่อนปี 1940)	บอกว่าเป็นย่านเมืองเก่าหรือเมืองใหม่
DIS	ระยะห่างจากแหล่งงานหลัก 5 แห่ง	บ้านไกลที่ทำงานอาจราคาถูกลง แต่เดินทางลำบาก
RAD	ดัชนีการเข้าถึงทางหลวงสายหลัก	ความสะดวกในการเดินทางด้วยรถยนต์
TAX	อัตราภาษีที่ดินต่อ \$10,000	ค่าใช้จ่ายแฝงของการเป็นเจ้าของบ้านในเขตนั้น
PTRATIO	อัตราส่วนนักเรียนต่อครูในพื้นที่	สะท้อนถึงภาพการศึกษา
LSTAT	% ประชากรที่มีสถานะทางสังคมต่ำ	ตัวบ่งชี้ความยากจนในพื้นที่ ส่งผลลบต่อมูลค่าบ้าน
MEDV	มูลค่าบ้านเฉลี่ย (ตัวแปรเป้าหมาย)	หน่วยเป็น \$1,000 (เช่น 24 = \$24,000)
CAT. MEDV	บ้านราคาสูงหรือไม่?	1 = ราคาเกิน \$30,000, 0 = ไม่เกิน (ใช้สำหรับ Classification)

1. การนำเข้าข้อมูล (Data Import)

- 1) Read CSV → BostonHousing.csv
- 2) เชื่อมต่อพอร์ต out ของข้อมูลเข้ากับพอร์ต res (result) แล้วกดปุ่มรัน (ปุ่มสีฟ้า)
- 3) ตรวจสอบแท็บ Statistics
 - มองหาตัวแปร MEDV (มูลค่าบ้านเฉลี่ย): มีค่าเฉลี่ยเท่าไร? ค่าสูงสุด-ต่ำสุดคือเท่าไร?
 - ตรวจสอบว่ามีข้อมูลสูญหาย (Missing Values) หรือไม่?

2. การสร้างแผนภูมิเพื่อวิเคราะห์ธุรกิจ (Visualization Lab)

คลิกที่แท็บ Visualizations ทางด้านซ้าย และลองสร้างกราฟดังนี้:

2.1 ตรวจสอบการกระจายตัวของราคาบ้าน

- เลือก Plot Type: **Histogram**
- เลือก Value Column: MEDV
- คำถาม: กราฟมีลักษณะเบี่ยงไปทางไหน?

2.2 หาความสัมพันธ์ระหว่างจำนวนห้องกับราคาบ้าน


- เลือก Plot Type: **Scatter**
- เลือก X-Axis: RM (จำนวนห้องเฉลี่ย)
- เลือก Y-Axis: MEDV
- คำถาม: เมื่อจำนวนห้องเพิ่มขึ้น ราคาบ้านมีแนวโน้มอย่างไร?

2.3 ระบุค่าผิดปกติ (Outliers)

- เลือก Plot Type: **Box Color** (Box Plot)
- เลือก Value Column: CRIM (อัตราอาชญากรรม) หรือ LSTAT (% ประชากรรายได้น้อย)
- คำถาม: ข้อมูลบนกราฟมีความผิดปกติหรือไม่ จุดนั้นหมายความว่าอย่างไรในเชิงธุรกิจ?

2.4 ดูความต่างของราคาผ่าน Box Plot แยกกลุ่มติดแม่น้ำ/ไม่ติดแม่น้ำ

- เลือก Plot Type: **Box Color** (Box Plot)
- เลือก Value Column: MEDV
- **Group by:** เลือก CHAS (เพื่อแยกกลุ่มตามการติดแม่น้ำ)



ในบางครั้ง RapidMiner อาจมองว่า CHAS เป็นตัวเลข (Integer) จะพยายามคำนวณ ให้ใช้ Operator **Numerical to Polynomial** วางก่อนหน้าแล้วเลือกตัวแปร CHAS

3. การลดมิติข้อมูล (Dimension Reduction Lab)

กลับไปที่แท็บ Design เพื่อวาง Operator เพิ่มเติม:

3.1: การสร้าง Correlation Matrix

1. ค้นหา Operator ชื่อ **Correlation Matrix** แล้วนำมาวางต่อจากข้อมูล
2. รันโปรแกรม และดูผลลัพธ์ที่แท็บ **Matrix**
3. **การวิเคราะห์:** ตัวแปรคู่ไหนที่มีค่าใกล้เคียง 1 หรือ -1 มากที่สุด? (ถ้าสูงมาก เช่น > 0.9 เราอาจจะเลือกตัดตัวใดตัวหนึ่งออกเพื่อลดความซ้ำซ้อน)

3.2: การทำ PCA (Principal Component Analysis)

1. ค้นหา Operator ชื่อ **Principal Component Analysis** วางต่อจากข้อมูล
2. ตั้งค่าใน Parameters: dimensionality reduction $\rightarrow$ keep variance (ตั้งค่าเป็น 0.95)
3. รันโปรแกรม และดูผลลัพธ์ในแท็บ **Attributes**
4. **การวิเคราะห์:** จากเดิมที่มีตัวแปร 13-14 ตัว หลังจากทำ PCA แล้ว เหลือ "ส่วนประกอบหลัก" (PC) กี่ตัวที่ยังคงรักษาข้อมูลส่วนใหญ่ไว้ได้?

สรุปผลการทดลอง:

ให้นักศึกษาเขียนสรุปสั้นๆ ว่า:

1. ปัจจัยใด (ตัวแปรใด) ที่ดูเหมือนจะมีผลต่อราคาบ้านมากที่สุดจากการดูด้วยตาเปล่า (Visualization)?
 2. การทำ Dimension Reduction ช่วยให้อะไรดีขึ้น? "กะทัดรัด" ขึ้นได้อย่างไร?
-

Principal Component Analysis (PCA) คือการ "ลดมิติของข้อมูล (Dimensionality Reduction)" โดยพยายามรักษาข้อมูลสำคัญ (Variance) เอาไว้ให้ได้มากที่สุด เป็นหนึ่งในเทคนิคที่สำคัญและนิยมใช้กันมาก

การทำงานของ PCA

Project ข้อมูลจากหลายมิติ ให้เหลือมิติน้อยลง โดยพยายามรักษา "ความกระจาย" (Variance) หรือสาระสำคัญของข้อมูลเดิมไว้ให้มากที่สุด

1. การปรับข้อมูลให้เป็นมาตรฐาน (Standardization)

เนื่องจากตัวแปรแต่ละตัวอาจมีหน่วยวัดไม่เท่ากัน (เช่น ในไฟล์ Cereals ของ Sodium มีค่าเป็นหลักร้อย แต่ Fat มีค่าแค่ 0-5) PCA จะทำงานได้ไม่ดีถ้าไม่ปรับสเกลก่อน ขั้นตอนนี้คือการทำให้ทุกตัวแปรมีค่าเฉลี่ยเป็น 0 และส่วนเบี่ยงเบนมาตรฐานเป็น 1 เพื่อให้ทุกตัวแปร "มีความสำคัญเท่ากัน" ในตอนเริ่มต้น

2. การหาความสัมพันธ์ (Covariance Matrix)

PCA จะคำนวณดูว่าตัวแปรแต่ละตัวมีความสัมพันธ์กันอย่างไร (เช่น ถ้าน้ำตาลสูง แคลอรี่จะสูงตามด้วยไหม?) เพื่อดูว่ามีข้อมูลส่วนไหนที่ "ซ้ำซ้อน" กันบ้าง

3. การสร้างแกนใหม่ (Principal Components)

นี่คือหัวใจของ PCA ระบบจะคำนวณหาเส้นตรง (แกน) ใหม่ขึ้นมา โดยมีเงื่อนไขดังนี้:

- **PC1 (แกนที่ 1):** คือเส้นที่ลากผ่านข้อมูลแล้วทำให้ข้อมูล "กระจายตัว" มากที่สุด (เก็บรายละเอียดได้มากที่สุด)
- **PC2 (แกนที่ 2):** คือเส้นที่ลากตั้งฉากกับ PC1 และเก็บรายละเอียดส่วนที่เหลือได้มากที่สุด
- ทำแบบนี้ไปเรื่อยๆ จนครบจำนวนตัวแปรเดิม

4. การเลือกแกนหลัก (Dimensionality Reduction)

หลังจากได้แกนใหม่มาแล้ว (PC1, PC2, PC3, ...) เรามักจะพบว่า **แค่ PC1 และ PC2 ก็สามารถเก็บข้อมูลส่วนใหญ่ (เช่น 80-90%) ของทั้งหมดไว้ได้แล้ว** เราจึงเลือกใช้แค่ 2 แกนนี้แทนตัวแปรเดิมนับสิบตัว

ประโยชน์ในงาน Data Mining:

1. **ลดการคำนวณ:** ถ้าข้อมูลมี 100 คอลัมน์ คอมพิวเตอร์จะทำงานหนัก แต่ถ้าลดเหลือ 5 แกนหลัก จะทำงานเร็วขึ้นมาก
2. **ช่วยในการ Plot กราฟ:** เราไม่สามารถวาดกราฟ 10 มิติได้ แต่ PCA ช่วยลดเหลือ 2 มิติเพื่อให้เราเห็นการเกาะกลุ่ม (Cluster) ของข้อมูลได้
3. **ลด Noise:** ส่วนที่ PCA ตัดทิ้งไปมักจะเป็นข้อมูลส่วนน้อยหรือสัญญาณรบกวน (Noise) ทำให้ Model แม่นยำขึ้นในบางกรณี

สรุปการอ่านด้วยตัวอย่าง (สมมติเลขจาก BostonHousing)

Component	Std. Deviation	Proportion of Variance	Cumulative Variance
PC 1	2.50	0.47	0.47
PC 2	1.60	0.19	0.66
PC 3	1.20	0.11	0.77

Standard Deviation (ส่วนเบี่ยงเบนมาตรฐาน) ค่านี้บอก "ความกว้าง" ของการกระจายตัวของข้อมูลบนแกนนั้นๆ

Proportion of Variance (สัดส่วนความแปรปรวน) บอกว่า "แกนนี้ตัวเดียว เก็บข้อมูลไว้ได้กี่ % จากทั้งหมด"

Cumulative Variance (ความแปรปรวนสะสม) ตัวอย่าง PC 2: 0.66 (มาจาก 0.47 + 0.19)

วิเคราะห์จากตารางข้างต้น

- 1. Eigenvalue ของ PC 1 คือ $2.50^2=6.25$ (ถือว่าสูงมาก เก็บข้อมูลได้เยอะ)
- 2. แค่ใช้ PC 1 ถึง PC 3 ก็สามารถอธิบายลักษณะบ้านใน Boston ได้ถึง 77% แล้ว ทั้งที่ลดจำนวนตัวแปรจาก 13 เหลือแค่ 3 ตัว
- 3. ถ้าจะ Plot กราฟ 2 มิติเพื่อดูการจับกลุ่มของบ้าน จะสูญเสียข้อมูลไปประมาณ 34% (100% – 66%) ซึ่งถือว่ายังพอยอมรับได้ในงาน Data Mining ส่วนใหญ่