

Lab Sheet 4-1: การลดมิติข้อมูลด้วย Principal Component Analysis (PCA)

หัวข้อ: การวิเคราะห์ส่วนประกอบหลักเพื่อจัดกลุ่มสารอาหารในซีเรียล (บทที่ 4) **ชุดข้อมูล:** Cereals.csv (77 Breakfast Cereals)

วัตถุประสงค์:

- เข้าใจขั้นตอนการทำ PCA เพื่อลดความซ้ำซ้อนของข้อมูล
- ฝึกการทำ Data Normalization (Z-score) ก่อนเข้ากระบวนการ PCA
- ตีความผลลัพธ์ของ Principal Components (PC) ในเชิงธุรกิจ/โภชนาการ

TABLE 4.4 DESCRIPTION OF THE ATTRIBUTES IN THE BREAKFAST CEREAL DATASET

Variable	Description
mfr	Manufacturer of cereal (American Home Food Products, General Mills, Kellogg, etc.)
type	Cold or hot
calories	Calories per serving
protein	Grams of protein
fat	Grams of fat
sodium	Milligrams of sodium
fiber	Grams of dietary fiber
carbo	Grams of complex carbohydrates
sugars	Grams of sugars
potass	Milligrams of potassium
vitamins	Vitamins and minerals: 0, 25, or 100, indicating the typical percentage of FDA recommended
shelf	Display shelf (1, 2, or 3, counting from the floor)
weight	Weight in ounces of one serving
cups	Number of cups in one serving
rating	Rating of the cereal calculated by consumer reports

ขั้นตอนการปฏิบัติใน RapidMiner:

1. การเตรียมข้อมูล (Preprocessing)

- นำไฟล์ Cereals.csv เข้าสู่ Process
- ใช้ Operator **Select Attributes**:
 - เลือกเฉพาะตัวแปรที่เป็นตัวเลข (Nutrients): calories, protein, fat, sodium, fiber, carbo, sugars, potass, vitamins.
- ใช้ Operator **Replace Missing Values**: ตั้งค่าเป็น average (ป้องกัน Error จากข้อมูลที่หายไป)

4. สำคัญมาก: ใช้ Operator Normalize:

- ตั้งค่า Method เป็น Z-transformation.
- เหตุผล: สารอาหารแต่ละตัวมีหน่วยต่างกัน (มิลลิกรัม vs กรัม) PCA จะทำงานได้ถูกต้องเมื่อข้อมูลอยู่ในสเกลเดียวกัน

2. การทำ PCA (Dimensionality Reduction)

1. ค้นหาและวาง Operator **Principal Component Analysis** ต่อจาก Normalize

2. ในช่อง **Parameters** ปรับค่าดังนี้:

- dimensionality reduction: เลือก **keep variance**
- variance threshold: ใส่ค่า **0.95** (หมายถึงเราต้องการรักษาข้อมูลส่วนใหญ่ไว้ 95%)

3. การรันและตีความผลลัพธ์ (Analysis)

กดปุ่ม **Run** และตรวจสอบผลลัพธ์ในแท็บต่างๆ:

• 3.1 แท็บ Eigenvalues (Cumulative Variance):

- ดูว่าต้องใช้ PC ทั้งหมดกี่ตัวเพื่อให้ได้ Cumulative Variance เกิน 95%? (โดยปกติจะเหลือเพียง 3-4 ตัวจากเดิม 9 ตัว)

• 3.2 แท็บ PCA Loadings (Eigenvectors):

- ดูตารางความสัมพันธ์ระหว่าง PC กับตัวแปรเดิม:
- ตัวอย่าง: หาก **PC1** มีค่าเป็นบวกสูงใน calories และ fat แต่มีค่าเป็นลบใน fiber เราอาจตั้งชื่อ PC1 ว่าเป็น **"มิติของความอ้วน"** (Unhealthy dimension).

• 3.3 แท็บ Visualizer (Scatter Plot):

- เลือกแกน X เป็น **PC1** และแกน Y เป็น **PC2**
- กิจกรรม: ลองดูว่าซีเรียลตัวไหนที่กระโดดแยกออกมา (Outliers) หรือเกาะกลุ่มกัน แสดงว่าพวกมันมีโปรไฟล์สารอาหารที่คล้ายกันมาก

คำถามท้ายกิจกรรม:

1. ก่อนทำ PCA เรามีตัวแปรสารอาหารกี่ตัว? และหลังทำ PCA (ที่ 95% Variance) เหลือเพียงกี่ตัว?
2. หากต้องอธิบาย **PC1** ให้คนทั่วไปฟัง คุณจะเรียกมิตินี้ว่าอะไร (ดูจากตัวแปรที่มีอิทธิพลสูงที่สุด)?
3. ทำไมเราถึงต้องทำ Normalize ก่อนทำ PCA เสมอ? (ลองรันแบบไม่ Normalize แล้วดูผลลัพธ์ที่เปลี่ยนไป)