

LAB6-1 Multiple Linear Regression

ชุดข้อมูล: BostonHousing.csv

วัตถุประสงค์:


1. เข้าใจการคัดเลือกตัวแปร
2. เข้าใจการออกแบบโมเดลที่ดี

TABLE 4.1 DESCRIPTION OF ATTRIBUTES IN THE BOSTON HOUSING DATASET

CRIM	Crime rate
ZN	Percentage of residential land zoned for lots over 25,000 ft ²
INDUS	Percentage of land occupied by nonretail business
CHAS	Does tract bound Charles River? (= 1 if tract bounds river, = 0 otherwise)
NOX	Nitric oxide concentration (parts per 10 million)
RM	Average number of rooms per dwelling
AGE	Percentage of owner-occupied units built prior to 1940
DIS	Weighted distances to five Boston employment centers
RAD	Index of accessibility to radial highways
TAX	Full-value property tax rate per \$10,000
PTRATIO	Pupil-to-teacher ratio by town
LSTAT	Percentage of lower status of the population
MEDV	Median value of owner-occupied homes in \$1000s
CAT.MEDV	Is median value of owner-occupied homes in tract above \$30,000 (CAT.MEDV = 1) or not (CAT.MEDV = 0)?

ชื่อตัวแปร	ความหมาย (แปลไทย)	คำอธิบายเชิงธุรกิจ
CRIM	อัตราอาชญากรรมต่อหัว	พื้นที่ที่มีอาชญากรรมสูง มักส่งผลลบต่อราคาบ้าน
ZN	สัดส่วนพื้นที่ดินจัดสรรขนาดใหญ่	บอกถึงความเป็นย่านที่พักอาศัยระดับหรู
INDUS	สัดส่วนพื้นที่อุตสาหกรรม	ย่านโรงงานเยอะ อาจมีมลภาวะหรือเสียงดัง
CHAS	ติดแม่น้ำ Charles หรือไม่?	ตัวแปรหุ่น (Dummy): 1 = ติดแม่น้ำ (วิวดูดี), 0 = ไม่ติด
NOX	ความเข้มข้นของก๊าซไนโตรเจนออกไซด์	ดัชนีวัดมลพิษทางอากาศในพื้นที่นั้น
RM	จำนวนห้องเฉลี่ยต่อหลัง	สำคัญมาก: บ้านห้องเยอะ ราคา มักจะสูงตาม
AGE	สัดส่วนบ้านเก่า (สร้างก่อนปี 1940)	บอกว่าเป็นย่านเมืองเก่าหรือเมืองใหม่
DIS	ระยะห่างจากแหล่งงานหลัก 5 แห่ง	บ้านไกลที่ทำงานอาจราคาถูกลง แต่เดินทางลำบาก
RAD	ดัชนีการเข้าถึงทางหลวงสายหลัก	ความสะดวกในการเดินทางด้วยรถยนต์
TAX	อัตราภาษีที่ดินต่อ \$10,000	ค่าใช้จ่ายแฝงของการเป็นเจ้าของบ้านในเขตนั้น
PTRATIO	อัตราส่วนนักเรียนต่อครูในพื้นที่	สะท้อนถึงภาพการศึกษา
LSTAT	% ประชากรที่มีสถานะทางสังคมต่ำ	ตัวบ่งชี้ความยากจนในพื้นที่ ส่งผลลบต่อมูลค่าบ้าน
MEDV	มูลค่าบ้านเฉลี่ย (ตัวแปรเป้าหมาย)	หน่วยเป็น \$1,000 (เช่น 24 = \$24,000)
CAT. MEDV	บ้านราคาสูงหรือไม่?	1 = ราคาเกิน \$30,000, 0 = ไม่เกิน (ใช้สำหรับ Classification)

1. สร้าง Process ตามนี้ (ใช้ข้อมูล BostonHousing.csv, MEDV (ราคาบ้าน) เป็นตัวแปร Y)



2. **Select Attributes:** ถ้าใช้ตัวแปรน้อย แล้วพยากรณ์ได้แม่นยำ ย่อมทำให้โมเดลนั้นเข้าใจง่าย เราจะเลือกตัวแปรที่ดีได้อย่างไร

เทคนิคการเลือกตัวแปร (Variable Selection) ใน RapidMiner อาจารย์สามารถสอนวิธีเลือกตัวแปรที่ดีที่สุดได้ 3 วิธี:

1) **Forward Selection:** เริ่มจากศูนย์แล้วค่อยๆ หยิบตัวแปรที่ดีที่สุดใส่ทีละตัว

2) **Backward Elimination:** ใส่ทุกตัวแปรแล้วค่อยๆ ตัดตัวแปรที่ห่วยที่สุด (p-value สูงสุด) ออกทีละตัว

3) **Stepwise Selection:** ผสมทั้งสองวิธีเข้าด้วยกัน

3. Set role: MEDV = label

4. Correlation Matrix ไว้ดูความสัมพันธ์ของตัวแปร เพื่อใช้เลือกตัวแปร

5. **Linear Regression:** ที่ Parameter ให้ตั้งค่า **feature selection** เป็น M5 prime หรือ Greedy เพื่อให้โปรแกรมช่วยคัดเลือกตัวแปรที่สำคัญให้อัตโนมัติ

6. **Performance (Regression):** นอกจาก **Root Mean Squared Error (RMSE)** แล้วให้เลือก **Squared Correlation (R2)** เพิ่มด้วย

- Root Mean Squared Error (RMSE): ยิ่งน้อยยิ่งดี
- Squared Correlation (R2): ยิ่งใกล้ 1 ยิ่งดี

7. อ่านค่า Correlation Matrix

Attribu...	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	LSTAT	MEDV	CAT. M...
CRIM	1	-0.200	0.407	-0.056	0.421	-0.219	0.353	-0.380	0.626	0.583	0.290	0.456	-0.388	-0.152
ZN	-0.200	1	-0.534	-0.043	-0.517	0.312	-0.570	0.664	-0.312	-0.315	-0.392	-0.413	0.360	0.365
INDUS	0.407	-0.534	1	0.063	0.764	-0.392	0.645	-0.708	0.595	0.721	0.383	0.604	-0.484	-0.366
CHAS	-0.056	-0.043	0.063	1	0.091	0.091	0.087	-0.099	-0.007	-0.036	-0.122	-0.054	0.175	0.109
NOX	0.421	-0.517	0.764	0.091	1	-0.302	0.731	-0.769	0.611	0.668	0.189	0.591	-0.427	-0.233
RM	-0.219	0.312	-0.392	0.091	-0.302	1	-0.240	0.205	-0.210	-0.292	-0.356	-0.614	0.695	0.641
AGE	0.353	-0.570	0.645	0.087	0.731	-0.240	1	-0.748	0.456	0.506	0.262	0.602	-0.377	-0.191
DIS	-0.380	0.664	-0.708	-0.099	-0.769	0.205	-0.748	1	-0.495	-0.534	-0.232	-0.497	0.250	0.119
RAD	0.626	-0.312	0.595	-0.007	0.611	-0.210	0.456	-0.495	1	0.910	0.465	0.489	-0.382	-0.198
TAX	0.583	-0.315	0.721	-0.036	0.668	-0.292	0.506	-0.534	0.910	1	0.461	0.544	-0.469	-0.274
PTRATIO	0.290	-0.392	0.383	-0.122	0.189	-0.356	0.262	-0.232	0.465	0.461	1	0.374	-0.508	-0.443
LSTAT	0.456	-0.413	0.604	-0.054	0.591	-0.614	0.602	-0.497	0.489	0.544	0.374	1	-0.738	-0.470
MEDV	-0.388	0.360	-0.484	0.175	-0.427	0.695	-0.377	0.250	-0.382	-0.469	-0.508	-0.738	1	0.790
CAT. ME...	-0.152	0.365	-0.366	0.109	-0.233	0.641	-0.191	0.119	-0.198	-0.274	-0.443	-0.470	0.790	1

วิธีอ่านค่าเบื้องต้น

ค่าในตารางจะอยู่ระหว่าง -1 ถึง 1:

- **เข้าใกล้ 1:** สัมพันธ์กันแบบ **แปรผันตามกัน** (ตัวหนึ่งเพิ่ม อีกตัวเพิ่ม) เช่น จำนวนห้อง (RM) กับราคาบ้าน (MEDV)
- **เข้าใกล้ -1:** สัมพันธ์กันแบบ **แปรผกผัน** (ตัวหนึ่งเพิ่ม อีกตัวลด) เช่น ความยากจน (LSTAT) กับราคาบ้าน (MEDV)
- **เข้าใกล้ 0:** **ไม่มีความสัมพันธ์กัน** หรือแทบไม่ส่งผลต่อกันเลย

A. มองหา "พระเอก" (สัมพันธ์กับราคาบ้าน MEDV สูงๆ)

ให้นักศึกษาดูที่แถวหรือคอลัมน์ MEDV ครับ เราจะพบตัวแปรที่ส่งผลต่อราคาบ้านชัดเจนที่สุดคือ:

- **RM (0.695):** สัมพันธ์เชิงบวกสูงมาก (ห้องเยอะ บ้านแพง)
- **LSTAT (-0.738):** สัมพันธ์เชิงลบสูงมาก (ย่านคนจนเยอะ บ้านราคาถูกลง)
- **PTRATIO (-0.508):** สัมพันธ์เชิงลบ (ครูต่อนักเรียนน้อย/คุณภาพโรงเรียนต่ำ ราคาบ้านลดลง)

Insight: 3 ตัวนี้คือ "Candidate" แรกๆ ที่ต้องมีในโมเดลครับ

B. ระวัง "ตัวร้าย" (Multicollinearity – สัมพันธ์กันเองสูง)

นี่คือจุดที่นักศึกษา มักพลาดครับ ให้ลองหาคู่ X ที่สัมพันธ์กันเอง เกิน 0.7 หรือ 0.8 เช่น:

- **TAX กับ RAD (0.910):** สูงมาก! (ย่านที่ใกล้ทางหลวงมักมีภาษีสูง)
- **NOX กับ INDUS (0.764):** สูง (ย่านอุตสาหกรรมมักมีมลพิษเยอะ)
- **DIS กับ AGE (-0.748):** สูง (บ้านเก่ามักอยู่ใกล้ศูนย์กลางแหล่งงาน)

Action: หากเจอคู่ที่สูงขนาดนี้ (เช่น TAX กับ RAD) **ไม่ควรใส่ในโมเดลพร้อมกันทั้งคู่** เพราะจะทำให้ค่าสถิติรวน (Multicollinearity) ควรเลือกมาแค่ตัวเดียวครับ

8. วิธีการตัดตัวแปร (Backward Elimination) โดยดูค่า p-value

LinearRegression (Linear Regression)

PerformanceVector (Performance)

ExampleSet (Apply Model)

Correlation Matrix (Correlation Matrix)

Attribute	Coefficient	Std. Error	Std. Coefficient	Tolerance	t-Stat	p-Value	Code
CRIM	-0.113	0.027	-0.113	0.598	-4.122	0.000	****
ZN	-0.011	0.014	-0.026	0.429	-0.820	0.413	
INDUS	0.096	0.063	0.069	0.218	1.531	0.127	
CHAS	2.591	0.822	0.070	0.906	3.153	0.002	***
NOX	-13.848	3.464	-0.171	0.244	-3.997	0.000	****
RM	1.066	0.401	0.081	0.478	2.659	0.008	***
DIS	-0.659	0.187	-0.146	0.261	-3.523	0.000	****
RAD	0.165	0.062	0.151	0.142	2.685	0.008	***
TAX	-0.008	0.004	-0.141	0.105	-2.165	0.031	**
PTRATIO	-0.550	0.125	-0.128	0.531	-4.407	0.000	****
LSTAT	-0.503	0.044	-0.383	0.397	-11.397	0	****
CAT. MEDV	11.998	0.777	0.478	0.466	15.432	0	****
(Intercept)	41.501	4.577	?	?	9.068	0	****

วิธีการ

ตัดตัวที่ p-value สูงที่สุดออก 1 ตัว -> แล้วรันใหม่ -> แล้วดู p-value ของตัวที่เหลือ

เหตุผล: เพราะเมื่อเราตัดตัวหนึ่งออก ค่า p-value ของตัวที่เหลืออาจจะเปลี่ยนไป

ทำซ้ำ: จนกว่าทุกตัวที่เหลือจะมีความสำคัญ ($p\text{-value} < 0.05$) ทั้งหมด ** 0.05 เป็นเกณฑ์เริ่มต้นที่นิยมใช้

บันทึก ทานตัดตัวแปรใดออกบ้าง และค่า RMSE เปลี่ยนไปเช่นไร

กฎการตัดสินใจเลือกโมเดล (Model Selection Rules)

1. กฎความเรียบง่าย (Principle of Parsimony / Occam's Razor) หากมี 2 โมเดลที่ให้ผลลัพธ์ใกล้เคียงกัน ให้เลือกโมเดลที่ "ใช้ตัวแปรน้อยกว่า"

2. ศูนย์สำคัญทางสถิติ (P-Value)

- หลักการ: ตัวแปรที่นำมาใส่ในสมการควรมีค่า P-Value < 0.05 (หรือมีสัญลักษณ์ดาวใน RapidMiner)
- เหตุผล: หาก P-Value สูง แปลว่าความสัมพันธ์นั้นอาจเกิดขึ้นโดยบังเอิญ การเก็บตัวแปรเหล่านี้ไว้จะทำให้โมเดลเกิด Overfitting คือเก่งแค่กับข้อมูลเก่า แต่พังเมื่อเจอข้อมูลใหม่

3. ตรวจสอบความซ้ำซ้อน (Multicollinearity)

- หลักการ: หลีกเลี่ยงการใช้ตัวแปรที่ "บอกเรื่องเดียวกัน" ($\text{Correlation} > 0.8$)
- กรณีศึกษาของเรา: RAD กับ TAX สัมพันธ์กันสูงมาก (0.91) การเก็บไว้ทั้งคู่จะทำให้ค่า Coefficient ของเรา "เหวี่ยง" และสรุปผลผิดพลาดได้