



Lab Sheet 7-1: Logistic Regression



1. สร้าง Process เพื่อทำ Logistic Regression โดยใช้ข้อมูล Titanic ใน Samples data
2. การเลือกข้อมูลและการจัดการค่าว่าง (Data Preprocessing)
 - Select Attributes: เลือกเฉพาะคอลัมน์ที่น่าจะเกี่ยวข้อง เช่น Age, Fare, Sex, Survived, Passenger Class
 - Replace Missing Values: เนื่องจาก Logistic Regression ไม่ชอบค่าว่าง (โดยเฉพาะในคอลัมน์ Age) ให้ใช้ Operator นี้เพื่อเติมค่าเฉลี่ย (Average) ลงไปในช่องที่ข้อมูลหายไป (ใน rapidminer ไม่ทำขั้นนี้ก็รันผ่านได้ เพราะมัน autofix ค่าความแม่นยำจะลดลง แต่ถ้าเป็น python ไม่ผ่านแน่นอน เพราะมันทำ operation อย่างเช่นการคูณไม่ได้)
3. การแปลงข้อมูล (Encoding)
 - Nominal to Numerical: อย่างที่เราคุยกันก่อนหน้านี้ Logistic Regression คำนวณจากตัวเลขเท่านั้น ให้ใช้ Operator นี้แปลงคอลัมน์ Sex และ Passenger Class ให้เป็น Dummy Coding (0 หรือ 1)
4. การกำหนดเป้าหมาย (Set Role) เลือกคอลัมน์ Survived (ซึ่งเป็น Nominal: Yes/No) ให้เป็น label
5. การสร้างโมเดล (Modeling) นำ Operator Logistic Regression มาวางและเชื่อมต่อ

6. การทดสอบและวัดผล (Validation)

- ใช้ Operator Split Data เพื่อแบ่งข้อมูล (เช่น 70% สำหรับ Train / 30% สำหรับ Test)



- ใช้ Apply Model เพื่อนำโมเดลไปใช้กับข้อมูล 30% ที่แบ่งไว้

7. ใช้ Performance (Classification) เพื่อดูค่า Accuracy และ Confusion Matrix

accuracy: 79.64%

	true Yes	true No	class precision	precision
pred. Yes	80	10	88.89%	$80/(80+10)$
pred. No	70	233	76.90%	$233/(70+233)$
class recall	53.33%	95.88%		
Recall	$80/(80+70)$	$233/(10+233)$		

$$\text{Accuracy } (80+233)/(80+10+70+233) = 79.64\%$$

8. ลากเส้น threshold จากโมเดลไปที่ result เพื่อดูค่า threshold ที่ระบบใช้

```

Threshold
Threshold: 0.35272673883795336
first class: Yes
second class: No
if confidence(No) > 0.35272673883795336 then No
else Yes
  
```

ถ้า confidence(No) มากกว่า 0.352 จะทำนายว่า No (เกณฑ์คือจุดนี้)

ข้อสังเกตสำคัญ: ในโมเดลนี้ ระบบคำนวณโอกาสของคลาส "No" (ไม่รอด หรือ ตาย) เป็นหลัก

9. การอ่านค่าตารางค่าสัมประสิทธิ์ (Coefficients) ของ Logistic Regression

Warning: Removed collinear columns [Passenger Class = Third, Sex = Male]					
Attribute	Coefficient	Std. Coefficient	Std. Error	z-Value	p-Value
Passenger Class = First	-2.208	-0.949	0.273	-8.091	0.000
Passenger Class = Second	-0.877	-0.364	0.214	-4.096	0.000
Passenger Class = Third	0	0	?	?	?
Sex = Female	-2.464	-1.180	0.179	-13.799	0
Sex = Male	0	0	?	?	?
Age	0.032	0.416	0.007	4.478	0.000
Passenger Fare	-0.000	-0.016	0.002	-0.155	0.877
Intercept	1.297	0.621	0.230	5.640	0.000

ค่า Coefficient (สัมประสิทธิ์)

- **Coefficient = 0:** หมายถึงกลุ่มนี้ถูกใช้เป็น **กลุ่มอ้างอิง** (Base Case) เพื่อเปรียบเทียบกับกลุ่มอื่น Logistic Regression จะเลือก **Base case** เพื่อเปรียบเทียบเสมอ
- ค่าที่เป็น บวก (+): ยิ่งเพิ่มโอกาสการเกิดผลลัพธ์นั้น (ในที่นี้คือ ไม่รอด/ตาย)
 - **Age (0.032):** ค่าเป็นบวกเล็กน้อย หมายความว่า ยิ่งอายุมาก โอกาสที่จะ "ตาย" เพิ่มขึ้น
- ค่าที่เป็น ลบ (-): ยิ่งลดโอกาสการเกิดผลลัพธ์นั้น เช่น
 - **Sex = Female (-2.464):** ผู้หญิงมีโอกาส "ตาย" น้อยกว่า ผู้ชายอย่างมาก

ค่า p-Value

คอลัมน์นี้บอกว่าเราควร "เชื่อ" ตัวแปรนั้นหรือไม่ โดยปกติเราจะใช้เกณฑ์ 0.05

- **Age, Sex, Passenger Class (p = 0.000):** ค่าเหล่านี้น้อยกว่า 0.05 แปลว่าปัจจัยเหล่านี้ **มีผลต่อการรอดชีวิตอย่างมีนัยสำคัญ** (เชื่อถือได้ 99.9%)
- **Passenger Fare (p = 0.877):** ค่านี้สูงกว่า 0.05 มาก แปลว่า **"ราคาตั๋ว" แทบไม่มีผลต่อการทำนายเลย** หากเรารู้ชั้นที่นั่ง (Class) อยู่แล้ว ข้อมูลราคาตั๋วก็ไม่จำเป็นต้องใช้ครับ

Intercept (1.297): คือคะแนนเริ่มต้นสำหรับกลุ่มอ้างอิง (ผู้ชาย ชั้น 3)

เมื่อเป็นผู้หญิง หรืออยู่ชั้น 1 คะแนนนี้จะถูกหักลบออกไปเยอะมาก ทำให้ความน่าจะเป็นที่จะ "ไม่รอด" ลดลง จนโมเดลทายว่า "Yes" (รอด) ในที่สุด