

Classification and Regression Trees (CART)

Kittirak Moungmingsuk

Classification and Regression Trees (CART)

CART เป็นอัลกอริทึมที่สร้าง "ต้นไม้ตัดสินใจ" (**Decision Tree**) โดยมีลักษณะเด่นคือเป็น **Binary Tree** (แต่ละโหนดจะแตกออกเป็น 2 กิ่งเสมอ) เพื่อใช้ในการพยากรณ์ข้อมูล:

- **Classification Trees:** ใช้เมื่อตัวแปรเป้าหมาย (**Target**) เป็นกลุ่มหรือหมวดหมู่ (เช่น ผ่าน/ไม่ผ่าน)
- **Regression Trees:** ใช้เมื่อตัวแปรเป้าหมายเป็นตัวเลขต่อเนื่อง (เช่น ราคาบ้าน)

กระบวนการสร้างต้นไม้ (**Recursive Binary Splitting**)

CART ใช้หลักการที่เรียกว่า **Top-down, Greedy Approach**:


- **Top-down**: เริ่มจากราก (**Root**) แล้วค่อยๆ แบ่งข้อมูลลงมา
- **Greedy**: ณ จุดที่แบ่งโหนด อัลกอริทึมจะเลือกการแบ่งที่ "ดีที่สุด" ในขณะนั้น" โดยไม่สนว่าการแบ่งครั้งหน้าจะเป็นอย่างไร

วิธีการ: ค้นหาตัวแปร (X_j) และจุดตัด (s) ที่ทำให้ข้อมูลที่ถูกแบ่งออกมามีความ "บริสุทธิ์" (**Purity**) มากที่สุด

Classification - Decision Tree

Example : Weather Data

	Outlook	Temperature	Humidity	Windy	Play
1	sunny	hot	high	FALSE	no
2	sunny	hot	high	TRUE	no
3	overcast	hot	high	FALSE	yes
4	rainy	mild	high	FALSE	yes
5	rainy	cool	normal	FALSE	yes
6	rainy	cool	normal	TRUE	no
7	overcast	cool	normal	TRUE	yes
8	sunny	mild	high	FALSE	no
9	sunny	cool	normal	FALSE	yes
10	rainy	mild	normal	FALSE	yes
11	sunny	mild	normal	TRUE	yes
12	overcast	mild	high	TRUE	yes
13	overcast	hot	normal	FALSE	yes
14	rainy	mild	high	TRUE	no



วัดความไม่บริสุทธิ์ (Measures of Impurity)

เกณฑ์การแบ่งโหนด (Splitting Criteria)

- สำหรับ **Classification**

- Gini Impurity (G): วัดความน่าจะเป็นที่จะทายผิด


$$G = 1 - \sum_{i=1}^K p_i^2$$

- Entropy (Cross-entropy): วัดความวุ่นวายของข้อมูล

$$D = - \sum_{i=1}^K p_i \log(p_i)$$

- สำหรับ **Regression**

- ใช้การลดค่า RSS (Residual Sum of Squares) หรือ MSE โดยจะพยายามแบ่งโหนดให้ค่าตัวเลขในกลุ่มนั้นๆ ใกล้เคียงกับค่าเฉลี่ยของกลุ่มมากที่สุด



Entropy and Information Gain

$$Gain(A) = I(p, n) - E(A)$$

$$E(A) = \sum_{i=1}^v \frac{p_i + n_i}{p + n} I(p_i, n_i)$$

$$I(p, n) = -\frac{p}{p+n} \log_2 \left(\frac{p}{p+n} \right) - \frac{n}{p+n} \log_2 \left(\frac{n}{p+n} \right)$$

Entropy คือการวัดค่า "Uncertainty" (ความไม่แน่นอน)

ค่า Gain สูง แสดงว่าแอททริบิวต์นั้นช่วยลดความวุ่นวาย (Entropy) ของข้อมูลได้มากที่สุด และจะถูกเลือกเป็นตัวแทนโหนด

Golf Playing

	Outlook	Temperature	Humidity	Windy	Play
1	sunny	hot	high	FALSE	no
2	sunny	hot	high	TRUE	no
3	overcast	hot	high	FALSE	yes
4	rainy	mild	high	FALSE	yes
5	rainy	cool	normal	FALSE	yes
6	rainy	cool	normal	TRUE	no
7	overcast	cool	normal	TRUE	yes
8	sunny	mild	high	FALSE	no
9	sunny	cool	normal	FALSE	yes
10	rainy	mild	normal	FALSE	yes
11	sunny	mild	normal	TRUE	yes
12	overcast	mild	high	TRUE	yes
13	overcast	hot	normal	FALSE	yes
14	rainy	mild	high	TRUE	no

$$I(p, n) = -\frac{p}{p+n} \log_2 \left(\frac{p}{p+n} \right) - \frac{n}{p+n} \log_2 \left(\frac{n}{p+n} \right)$$

เป็น **yes 9 ครั้ง no 5 ครั้ง**
จากทั้งหมด **14 ครั้ง**

$$\begin{aligned}
 I(9,5) &= -9/14 \log_2(9/14) - 5/14 \log_2(5/14) \\
 &= -(0.6429 * -0.64) - (0.3572 * -1.47) \\
 &= 0.4115 + 0.5451 \\
 &= 0.9366
 \end{aligned}$$

Entropy calculation

	Outlook	Temperature	Humidity	Windy	Play
1	sunny	hot	high	FALSE	no
2	sunny	hot	high	TRUE	no
3	overcast	hot	high	FALSE	yes
4	rainy	mild	high	FALSE	yes
5	rainy	cool	normal	FALSE	yes
6	rainy	cool	normal	TRUE	no
7	overcast	cool	normal	TRUE	yes
8	sunny	mild	high	FALSE	no
9	sunny	cool	normal	FALSE	yes
10	rainy	mild	normal	FALSE	yes
11	sunny	mild	normal	TRUE	yes
12	overcast	mild	high	TRUE	yes
13	overcast	hot	normal	FALSE	yes
14	rainy	mild	high	TRUE	no

$$\begin{aligned}E(\text{outlook}) &= 5/14 I(2,3) + 4/14 I(4,0) + 5/14 I(3,2) \\&= (0.3572 * 0.971) + (0.2858 * 0) + (0.3572 * 0.971) \\&= 0.3469 + 0 + 0.3469 \\&= 0.6937\end{aligned}$$

$$\begin{aligned}\text{Sunny } I(2,3) &= -2/5 \log_2 (2/5) - 3/5 \log_2 3/5 \\&= -(0.4 * -1.321928) - (0.6 * -0.736966) \\&= 0.5287 + 0.4422 \\&= 0.971\end{aligned}$$

$$\text{Overcast } I(4,0) = 0$$

$$\text{Rainy } I(3,2) = 0.971$$

$$\text{Gain(Outlook)} = 0.9366 - 0.6937 = 0.2429$$

Entropy calculation

	Outlook	Temperature	Humidity	Windy	Play
1	sunny	hot	high	FALSE	no
2	sunny	hot	high	TRUE	no
3	overcast	hot	high	FALSE	yes
4	rainy	mild	high	FALSE	yes
5	rainy	cool	normal	FALSE	yes
6	rainy	cool	normal	TRUE	no
7	overcast	cool	normal	TRUE	yes
8	sunny	mild	high	FALSE	no
9	sunny	cool	normal	FALSE	yes
10	rainy	mild	normal	FALSE	yes
11	sunny	mild	normal	TRUE	yes
12	overcast	mild	high	TRUE	yes
13	overcast	hot	normal	FALSE	yes
14	rainy	mild	high	TRUE	no

A. Humidity (ความชื้น)

มี 2 ค่าคือ High และ Normal

- High (7 ครั้ง): มี Yes 3, No 4 $\rightarrow I(3, 4) = -\frac{3}{7} \log_2(\frac{3}{7}) - \frac{4}{7} \log_2(\frac{4}{7}) \approx 0.985$
- Normal (7 ครั้ง): มี Yes 6, No 1 $\rightarrow I(6, 1) = -\frac{6}{7} \log_2(\frac{6}{7}) - \frac{1}{7} \log_2(\frac{1}{7}) \approx 0.592$
- $E(\text{Humidity}): \frac{7}{14}(0.985) + \frac{7}{14}(0.592) = 0.7885$
- $\text{Gain}(\text{Humidity}): 0.9366 - 0.7885 = \mathbf{0.1481}$

B. Windy (ลม)

มี 2 ค่าคือ TRUE และ FALSE

- TRUE (6 ครั้ง): มี Yes 3, No 3 $\rightarrow I(3, 3) = 1.0$ (ไม่แน่นอนสูงสุด)
- FALSE (8 ครั้ง): มี Yes 6, No 2 $\rightarrow I(6, 2) = -\frac{6}{8} \log_2(\frac{6}{8}) - \frac{2}{8} \log_2(\frac{2}{8}) \approx 0.811$
- $E(\text{Windy}): \frac{6}{14}(1.0) + \frac{8}{14}(0.811) = 0.892$
- $\text{Gain}(\text{Windy}): 0.9366 - 0.892 = \mathbf{0.0446}$

Entropy calculation

	Outlook	Temperature	Humidity	Windy	Play
1	sunny	hot	high	FALSE	no
2	sunny	hot	high	TRUE	no
3	overcast	hot	high	FALSE	yes
4	rainy	mild	high	FALSE	yes
5	rainy	cool	normal	FALSE	yes
6	rainy	cool	normal	TRUE	no
7	overcast	cool	normal	TRUE	yes
8	sunny	mild	high	FALSE	no
9	sunny	cool	normal	FALSE	yes
10	rainy	mild	normal	FALSE	yes
11	sunny	mild	normal	TRUE	yes
12	overcast	mild	high	TRUE	yes
13	overcast	hot	normal	FALSE	yes
14	rainy	mild	high	TRUE	no

C. Temperature (อุณหภูมิ)

มี 3 ค่าคือ Hot, Mild, Cool


- Hot (4 ครั้ง): Yes 2, No 2 $\rightarrow I(2, 2) = 1.0$
- Mild (6 ครั้ง): Yes 4, No 2 $\rightarrow I(4, 2) \approx 0.918$
- Cool (4 ครั้ง): Yes 3, No 1 $\rightarrow I(3, 1) \approx 0.811$
- $E(\text{Temperature}) = \frac{4}{14}(1.0) + \frac{6}{14}(0.918) + \frac{4}{14}(0.811) = 0.911$
- $\text{Gain}(\text{Temperature}) = 0.9366 - 0.911 = \mathbf{0.0256}$

สรุปผลการเปรียบเทียบค่า Gain

แอททริบิวต์	Information Gain
Outlook	0.2429 (จาก $0.9366 - 0.6937$)
Humidity	0.1481
Windy	0.0446
Temperature	0.0256

Entropy calculation

	Outlook	Temperature	Humidity	Windy	Play
1	sunny	hot	high	FALSE	no
2	sunny	hot	high	TRUE	no
3	overcast	hot	high	FALSE	yes
4	rainy	mild	high	FALSE	yes
5	rainy	cool	normal	FALSE	yes
6	rainy	cool	normal	TRUE	no
7	overcast	cool	normal	TRUE	yes
8	sunny	mild	high	FALSE	no
9	sunny	cool	normal	FALSE	yes
10	rainy	mild	normal	FALSE	yes
11	sunny	mild	normal	TRUE	yes
12	overcast	mild	high	TRUE	yes
13	overcast	hot	normal	FALSE	yes
14	rainy	mild	high	TRUE	no



Outlook มีค่า Gain สูงที่สุด จึงถูกเลือกเป็น Root Node

แบ่งต่อไปเรื่อย ๆ (**Recursive Binary Splitting**)

- เราคำนวณเพื่อหาความ "ไม่บริสุทธิ์" (**Impurity**) หากโหนดไหนยังมีค่าเอนโทรปีมากกว่า 0 แสดงว่าข้อมูลยังผสมกันอยู่ เราจึงต้อง "แบ่งต่อ" (**Split**) จนกว่าจะบริสุทธิ์ หรือจนกว่าจะเข้าเงื่อนไขให้หยุดกระบวนการนี้เรียกว่า **Recursive Binary Splitting**
- อย่างกรณีเราเลือก **Outlook** เป็น **Root Node** ไปแล้ว
 - กิ่ง Overcast: มีเอนโทรปีเป็น 0 (เป็น Yes ทั้งหมด) → หยุดแบ่ง และสรุปผลว่า "Yes"
 - กิ่ง Sunny: มีเอนโทรปี 0.971 (ยังไม่บริสุทธิ์) → ต้องแบ่งต่อ
 - กิ่ง Rainy: มีเอนโทรปี 0.971 (ยังไม่บริสุทธิ์) → ต้องแบ่งต่อ
- ทำงานไม่เหลือแอททริบิวต์ ให้แบ่งต่อแล้ว
- หรือ ถึงขีดจำกัด ที่เราตั้งไว้ (เช่น กำหนดความลึก **Max Depth** ไว้ที่ 3 ชั้น เพื่อป้องกัน **Overfitting**)

การจัดการกับ **Overfitting (Pruning)**

ถ้าเราปล่อยให้ต้นไม้โตไปเรื่อยๆ มันจะจำรายละเอียดขยะในข้อมูล (**Noise**) ทำให้เกิด **Overfitting** วิธีแก้คือ:

- **Pre-pruning:** กำหนดเงื่อนไขหยุดก่อนต้นไม้จะโตเกินไป (เช่น กำหนดความลึกสูงสุด)
- **Post-pruning (Cost Complexity Pruning):** สร้างต้นไม้ขนาดใหญ่ขึ้นมาก่อน แล้วค่อยๆ "ตัดกิ่ง" ที่ไม่สำคัญออก โดยใช้ค่า α (**Complexity Parameter**) เข้ามาควบคุม เพื่อหาจุดสมดุลระหว่างความแม่นยำและความซับซ้อน

Confusion matrix


	Outlook	Temperature	Humidity	Windy	Play
1	sunny	hot	high	FALSE	no
2	sunny	hot	high	TRUE	no
3	overcast	hot	high	FALSE	yes
4	rainy	mild	high	FALSE	yes
5	rainy	cool	normal	FALSE	yes
6	rainy	cool	normal	TRUE	no
7	overcast	cool	normal	TRUE	yes
8	sunny	mild	high	FALSE	no
9	sunny	cool	normal	FALSE	yes
10	rainy	mild	normal	FALSE	yes
11	sunny	mild	normal	TRUE	yes
12	overcast	mild	high	TRUE	yes
13	overcast	hot	normal	FALSE	yes
14	rainy	mild	high	TRUE	no

สมมติว่าจากข้อมูล 14 วัน (เล่น 9, ไม่เล่น 5) โมเดลของเราทำนายออกมาได้แบบนี้:

- วันที่มีความจริงว่า "เล่น" (Yes 9 วัน): โมเดลทายถูก 8 วัน, ทายผิดว่าไม่เล่น 1 วัน
- วันที่มีความจริงว่า "ไม่เล่น" (No 5 วัน): โมเดลทายถูก 3 วัน, ทายผิดว่าเล่น 2 วัน

	Predicted: YES	Predicted: NO
Actual: YES	8 (True Positive)	1 (False Negative)
Actual: NO	2 (False Positive)	3 (True Negative)

Example



- **Accuracy** : ทายถูกทั้งหมดกี่วัน?
 - $(TP+TN)/Total = (8+3)/14 \approx 78.5\%$
- **Precision** : ในบรรดาที่ทายว่า "เล่น" (10 วัน) ทายถูกจริงกี่วัน?
 - $TP/(TP+FP) = 8/(8+2) = 80\%$
- **Recall** : ในวันที่เขาเล่นกันจริงๆ (9 วัน) เราเก็บมาได้กี่วัน?
 - $TP/(TP+FN) = 8/(8+1) \approx 88.8\%$

Reference

<https://www.youtube.com/watch?v=eLIYSpVjH94>