


Lab1 Linear Regression

1 Linear regression on spreadsheet

1.1 สร้าง Spreadsheet คำนวณค่า Linear regression ให้ได้ผลลัพธ์ตามนี้




1.2 ทดลองใช้ฟังก์ชันสำเร็จรูปคำนวณค่า B_0 และ B_1

พารามิเตอร์	สูตร	ผลลัพธ์
β_1 (Slope)	=SLOPE(Y_range, X_range)	0.05
β_0 (Intercept)	=INTERCEPT(Y_range, X_range)	1.0

2. Linear regression on RapidMiner

ทำ Linear regression ด้วยข้อมูลราคาบ้านชุดเดิม บน RapidMiner โดยสร้างกระบวนการตามภาพ




โดยมี Operator ที่เกี่ยวข้องดังต่อไปนี้

Operator	หน้าที่
Read CSV	นำเข้าไฟล์ CSV ข้อมูลราคาบ้าน
Generate Attribute	ในปฏิบัติการนี้ใช้สำหรับแปลงราคาบ้านจากหลักล้านเป็นหลักหน่วย
Set Role	กำหนดบทบาทของคอลัมน์ X และ Y ให้โมเดลทราบ
Linear Regression	Operator หลักสำหรับสร้างแบบจำลองการถดถอยเชิงเส้น
Apply Model	ใช้โมเดลที่ฝึกสอนแล้วทำนายค่าในชุดข้อมูล

2.1 นำเข้าข้อมูล (Read CSV) (เพื่อเทรนนิ่ง)

- 1) ลาก Operator **Read CSV** เข้ามาใน Process Panel
- 2) ดับเบิลคลิกที่ **Read CSV** หรือคลิกที่ปุ่ม **Parameters** ด้านขวา
- 3) คลิก **Import Configuration Wizard** เพื่อนำทางไปยังไฟล์ CSV ของคุณ
- 4) ตรวจสอบให้แน่ใจว่า **Encoding** ถูกต้อง (เช่น UTF-8 หรือ Windows-1252) และ **Column Separator** ถูกต้อง (เช่น Comma)
- 5) ในขั้นตอนสุดท้ายของ Wizard ให้ตรวจสอบว่าคอลัมน์ "**ขนาดพื้นที่**" เป็นประเภท **Real** (ตัวเลข) และ "**ราคาบ้าน**" เป็นประเภท **Real** (ตัวเลข)




- 6) คลิก **Finish**

2.2 แปลงหน่วยราคาบ้าน

ในการคำนวณ การแปลงหน่วยราคาบ้านจาก "บาท" เป็น "ล้านบาท" จะช่วยลดตัวเลขลง ทำให้การประเมินประสิทธิภาพของโมเดล (RMSE) ง่ายขึ้น

- 1) ลาก Operator **Generate Attributes** เข้ามา
- 2) **เชื่อมต่อ:** Output ของ **Read CSV** → Input ของ **Generate Attributes**
- 3) ตั้งค่า **Parameters** ของ **Generate Attributes**



- คลิกที่รูปเครื่องคิดเลขทางขวา จะ popup windows แล้วมี Input ให้เลือก เขียนสูตร / 1000000 เพิ่มเข้าไป

2.3 กำหนดบทบาทตัวแปร (Set Role)

โมเดลจะต้องรู้ว่าคอลัมน์ไหนคือสิ่งที่เราต้องการทำนาย (Label)

- 1) ลาก Operator **Set Role** เข้ามา เชื่อมต่อ Output ของ **Read CSV** เข้ากับ Input ของ **Set Role**
- 2) ตั้งค่า **Parameters** ของ **Set Role** ดังนี้:
- 3) **Attribute Name:** เลือกคอลัมน์ **Price_Million**
- 4) **Target Role:** เลือก **label** (นี่คือตัวแปรตามที่เราต้องการทำนาย)
- 5) คอลัมน์ "**ขนาดพื้นที่**" target role เป็น **Regular**

2.4 ฝึกสอนโมเดล (Linear Regression)

- 1) ลาก Operator **Linear Regression** เข้ามา เชื่อมต่อ Output ของ **Set Role** เข้ากับ Input ของ **Linear Regression**
- 2) **Linear Regression** ไม่ต้องการการตั้งค่า **Parameters** เพิ่มเติมในเบื้องต้น

2.5 นำเข้าข้อมูล Read CSV(2) (เพื่อ predict)

ทำแบบข้อ 2.1 แต่ครั้งนี้ให้อ่าน CSV ไฟล์ HouseHowMuch.csv ที่มีข้อมูลดังต่อไปนี้

ขนาดพื้นที่(ตร.ม.),ราคาบ้าน(บาท) 100,
--

*ชื่อคอลัมน์บรรทัดแรกต้องตรงกับไฟล์แรกใช้เทรน

2.6 ทำนายผลและวัดประสิทธิภาพ (Apply Model & Performance)

- 1) ลาก **Operator Apply Model** เข้ามา
- 2) เชื่อมต่อ **mod (Model) Output** ของ **Linear Regression** เข้ากับ **mod Input** ของ **Apply Model**
- 3) เชื่อมต่อ **Output** ของ **Read CSV(2)** เข้ากับ **unl (Unlabeled Data) Input** ของ **Apply Model**
- 4) เชื่อมต่อ **Labelled data (lab)** ของ **Apply Model** เข้ากับ **Output Port** (พอร์ตด้านขวาของ **Process Panel**) แล้วคลิกปุ่ม **Run** (รูป Play)

ถ้าสำเร็จจะแสดงผลลัพธ์ตามภาพต่อไปนี้

ExampleSet (Apply Model)			
Open in  Turbo Prep  Auto Model  Interactive Analysis			
Row No.	prediction(...)	ขนาดพื้นที่(ตร....	ราคาบ้าน(บาท)
1	6.000	100	?


อ่านค่าได้ตามที่ทำบน **Spreadsheet** คือ ถ้าพื้นที่ 100 ตร.ม. ราคาบ้านจะอยู่ที่ 6 ล้านบาท

2.8 เพิ่มการทำ Performance Evaluation

- 1) ปรับข้อมูลในไฟล์ **HouseHowMuch.csv** โดยเพิ่มราคาบ้านเข้าไป เพื่อจะใช้เป็นข้อมูล **testing** (โมเดลทำนายว่า 6 ล้าน แต่เราตั้งใจใส่ 7 ล้าน เพื่อจะดูค่า **error**)

ขนาดพื้นที่(ตร.ม.),ราคาบ้าน(บาท)
100,7000000

- 2) ปรับ **Process** ใหม่ตามภาพต่อไปนี้



- แฉวล่างเพิ่ม **Generate Attribute** เพื่อปรับค่าราคาบ้านให้อยู่ในสัดส่วนเดียวกับ training data
- **Set role** ก็เหตุผลเดียวกับแฉวบน
- เพิ่ม Operator “**Performance (regression)**” เข้ามา เพื่อวัดประสิทธิภาพของโมเดล
- ที่ **Performance (regression)** ลากไป output สองเส้น เส้นหนึ่งค่าที่ทำนาย อีกเส้นค่า **RMSE (Root Mean Squared Error)**

ผลลัพธ์

ExampleSet (Apply Model)

PerformanceVector (Performance)

Open in

 Turbo Prep

 Auto Model

 Interactive Analysis

Row No.	Test_Price_...	prediction(...	ขนาดพื้นที่(ตร....	ราคาบ้าน(บาท)
1	7	6.000	100	7000000

ExampleSet (Apply Model) PerformanceVector (Performance)

Criterion
root mean squared er...

root_mean_squared_error
root_mean_squared_error: 1.000 +/- 0.000

RMSE = 1.000 หมายความว่า โมเดล Linear Regression ของคุณมีความผิดพลาดในการทำนายราคาบ้านโดยเฉลี่ยอยู่ที่ 1 ล้านบาท บนชุดข้อมูลทดสอบ 1 ชุด

- ขนาดพื้นที่ (X): 100 ตร.ม.
- ค่าจริง (Label): 7,000,000 บาท (หรือ 7.0 ล้านบาท เมื่อแปลงหน่วย)
- ค่าทำนาย (Prediction): 6.000 ล้านบาท

ความผิดพลาด (Error):

$$\text{Error} = |\text{ค่าจริง} - \text{ค่าทำนาย}| = |7.0 \text{ ล้าน} - 6.0 \text{ ล้าน}| = 1.0 \text{ ล้านบาท}$$

เนื่องจากคุณมีข้อมูลทดสอบเพียงแค่ 1 ชุด ค่า RMSE ที่คำนวณได้จึงเท่ากับ **ขนาดของความผิดพลาด** นั้นพอดีครับ (RMSE บนจุดเดียว = Absolute Error)

$$\text{RMSE} = \sqrt{\frac{(7.0 - 6.0)^2}{1}} = \sqrt{1^2} = 1.0$$

ข้อควรระวัง

- **ข้อมูลน้อยเกินไป:** การวัด RMSE จากจุดข้อมูลเพียง 1 ชุด ทำให้ค่าที่ได้ไม่น่าเชื่อถือในทางสถิติ การวัดประสิทธิภาพที่แท้จริงต้องใช้ **ชุดข้อมูลทดสอบ (Test Set)** ที่มีขนาดใหญ่และหลากหลายเพียงพอ (เช่น 20–30% ของข้อมูลทั้งหมด)
- **Bias/Variance:** โมเดลที่ฝึกสอนด้วยข้อมูล 5 ชุด และมี RMSE เป็น 1.0 (เมื่อเทียบกับช่วงราคา 2.5–7 ล้านบาท) บ่งชี้ว่าโมเดลอาจจะยัง **ไม่สามารถจับความสัมพันธ์จริง** ของราคาบ้านในตลาดได้ดีพอ